

Table des matières

Introduction	3
Section 1 : Importation et préparation des analyses	4
1.1 Importation du jeu de données préparé	4
1.2 Sélection des variables principales	5
Section 2 : Statistiques descriptives	6
2.1 Initialisation du tableau des statistiques descriptives	6
2.2 Calcul des statistiques descriptives	7
2.3 Mise en forme du tableau	7
2.4 Ajout de libellés lisibles	8
2.5 Affichage du tableau des statistiques descriptives	9
Section 3 : Visualisations descriptives	11
3.1 Préparation des libellés	11
3.2 Histogrammes	12
3.3 Boîtes à moustaches	13
3.4 Matrice de nuages de points	14
3.5 Matrice après transformation logarithmique	16
Section 4 : Corrélations linéaires de Pearson	18
4.1 Préparation des variables	18
4.2 Nuages de points	19
4.3 Calcul des corrélations de Pearson	21
4.4 Tableau récapitulatif des corrélations	22
Section 5 : Corrélations de Pearson après transformation logarithmique	24
5.1 Préparation des variables	24
5.2 Nuages de points	25
5.3 Calcul des corrélations de Pearson	26
5.4 Tableau récapitulatif des corrélations	28

Section 6 : Régression linéaire multiple	30
6.1 Préparation des données	30
6.2 Modèle initial	31
6.3 Corrélations entre les variables explicatives	32
6.4 Vérification de la multicollinéarité	33
6.5 Modèle sans la population	35
6.6 Modèle retenu	37
6.7 Validation graphique du modèle	38
6.8 Tableau des résultats de la régression	40
Section 7 : Analyse en composantes principales	41
7.1 Préparation des données	41
7.2 Réalisation de l'ACP	42
7.3 Interprétation des composantes	42
7.4 Représentation des bibliothèques	43
7.5 Variance expliquée	46
Section 8 : Sauvegarde des résultats	48
8.1 Préparation du dossier des résultats	48
8.2 Sauvegarde des tableaux	48
8.3 Confirmation de la sauvegarde	50
Conclusion	51
Bibliographie	52
Annexe	53

INTRODUCTION

Ce rapport présente les analyses statistiques réalisées dans le cadre du projet sur l'offre technologique et les profils des bibliothèques publiques de l'Ontario. Les analyses reposent sur les statistiques 2021 des bibliothèques publiques de l'Ontario, obtenues à partir du jeu de données publié par Sophie Bicanic sur Kaggle et provenant des données du gouvernement de l'Ontario. Le jeu de données a préalablement fait l'objet d'une préparation et d'un enrichissement afin de produire les variables et les indicateurs nécessaires aux analyses.

L'objectif est de mieux comprendre les différences entre les bibliothèques et d'examiner les relations entre leurs principales caractéristiques et l'offre technologique. Une attention particulière est accordée à l'indice de ressources technologiques et au ratio abonnés/population.

Les analyses débutent par un portrait descriptif des variables et l'examen de leur distribution. Des corrélations de Pearson sont ensuite réalisées sur les données originales, puis après transformation logarithmique des variables fortement asymétriques. Une régression linéaire multiple permet d'examiner simultanément les relations entre plusieurs caractéristiques des bibliothèques et l'indice technologique. Enfin, une analyse en composantes principales (ACP) permet de résumer l'information contenue dans plusieurs variables et de dégager les principales dimensions qui structurent les données.

Le rapport suit le déroulement du script R. Chaque étape présente son objectif, le code utilisé, les résultats obtenus et leur interprétation.

SECTION 1 : IMPORTATION ET PRÉPARATION DES ANALYSES

Cette section consiste à importer le jeu de données préparé lors des phases précédentes et à vérifier que les variables nécessaires aux analyses statistiques sont disponibles. Ces étapes permettent de confirmer que le jeu de données peut être utilisé pour les analyses descriptives, les corrélations, la régression et les analyses multivariées.

1.1 Importation du jeu de données préparé

Objectif

Importer le jeu de données nettoyé et enrichi afin de vérifier qu'il est accessible et qu'il peut être utilisé pour les analyses statistiques.

Code

Le chemin du fichier est d'abord défini et son existence est vérifiée.

```
fichier <- file.path(
  "Donnees",
  "Donnees preparees",
  "Bibliotheques_preparees.csv"
)

if (!file.exists(fichier)) {
  stop("Le fichier de données est introuvable : ", fichier)
}
```

Le jeu de données est ensuite importé dans R, puis ses dimensions, sa structure et ses premières observations sont affichées.

```
donnees <- read.csv(fichier, stringsAsFactors = FALSE)

dim(donnees)
str(donnees)
head(donnees)
```

Résultats

Le jeu de données contient 295 observations et 33 variables.

```
dim(donnees)
[1] 295 33
```

La structure complète du jeu de données et les six premières observations sont présentées à l'annexe A. Elles permettent de vérifier que les variables attendues sont présentes et que les données ont été importées correctement.

Analyse

L'importation s'est déroulée correctement. Le jeu de données préparé est accessible et peut être utilisé pour la suite des analyses.

1.2 Sélection des variables principales

Objectif

Sélectionner les principales variables qui seront utilisées dans les analyses statistiques.

Code

Les variables utilisées sont regroupées dans un vecteur.

```
variables_analyse <- c(
  "Population_desservie",
  "Nb_succursales",
  "Heures_ouverture",
  "Superficie",
  "Ratio_abonnes_population",
  "Indice_ressources_technologiques"
)
```

Résultats

Les six variables sélectionnées sont présentes dans le jeu de données.

```
names(donnees[, variables_analyse])

[1] "Population_desservie"      "Nb_succursales"
[3] "Heures_ouverture"         "Superficie"
[5] "Ratio_abonnes_population"  "Indice_ressources_technologiques"
```

Analyse

Les variables nécessaires aux analyses statistiques sont toutes présentes dans le jeu de données. Leur structure confirme qu'elles sont de type numérique, ce qui permet de les utiliser dans les analyses suivantes.

SECTION 2 : STATISTIQUES DESCRIPTIVES

Cette section présente les principales caractéristiques des variables étudiées. Le nombre d'observations, la moyenne, la médiane, l'écart-type ainsi que les valeurs minimale et maximale permettent d'obtenir un premier portrait des données avant de poursuivre avec les analyses statistiques.

2.1 Initialisation du tableau des statistiques descriptives

Objectif

Créer un tableau qui servira à regrouper les statistiques descriptives des variables retenues.

Code

Un tableau vide est créé avec les colonnes nécessaires pour recevoir les résultats.

```
statistiques_descriptives <- data.frame(  
  Variable = character(),  
  N = integer(),  
  Moyenne = numeric(),  
  Mediane = numeric(),  
  Ecart_type = numeric(),  
  Minimum = numeric(),  
  Maximum = numeric(),  
  stringsAsFactors = FALSE  
)
```

Résultats

Le tableau est initialisé et peut recevoir les statistiques calculées dans la section suivante.

Analyse

Cette étape permet de regrouper les statistiques descriptives dans un même tableau.

2.2 Calcul des statistiques descriptives

Objectif

Calculer les statistiques descriptives de chacune des variables sélectionnées.

Code

Une boucle traite successivement les six variables. Pour chacune d'elles, le nombre d'observations disponibles, la moyenne, la médiane, l'écart-type, le minimum et le maximum sont calculés, puis ajoutés au tableau.

```
for (variable in variables_analyse) {  
  valeurs <- donnees[[variable]]  
  
  ligne <- data.frame(  
    Variable = variable,  
    N = sum(!is.na(valeurs)),  
    Moyenne = mean(valeurs, na.rm = TRUE),  
    Mediane = median(valeurs, na.rm = TRUE),  
    Ecart_type = sd(valeurs, na.rm = TRUE),  
    Minimum = min(valeurs, na.rm = TRUE),  
    Maximum = max(valeurs, na.rm = TRUE)  
  )  
  
  statistiques_descriptives <-  
    rbind(statistiques_descriptives, ligne)  
}
```

Résultats

Les principales statistiques descriptives sont calculées pour les six variables sélectionnées.

Analyse

Ces statistiques permettent de comparer la tendance centrale, la dispersion et l'étendue des variables étudiées. Leur interprétation est présentée avec le tableau final à la section 2.5.

2.3 Mise en forme du tableau

Objectif

Arrondir les statistiques descriptives à deux décimales.

Code

Les statistiques numériques sont arrondies à deux décimales.

```
statistiques_descriptives$Moyenne <-  
  round(statistiques_descriptives$Moyenne, 2)  
  
statistiques_descriptives$Mediane <-  
  round(statistiques_descriptives$Mediane, 2)  
  
statistiques_descriptives$Ecart_type <-  
  round(statistiques_descriptives$Ecart_type, 2)  
  
statistiques_descriptives$Minimum <-  
  round(statistiques_descriptives$Minimum, 2)  
  
statistiques_descriptives$Maximum <-  
  round(statistiques_descriptives$Maximum, 2)
```

Résultats

Les résultats sont présentés avec une précision de deux décimales.

Analyse

Cette mise en forme facilite la lecture du tableau sans modifier les résultats des analyses.

2.4 Ajout de libellés lisibles

Objectif

Remplacer les noms techniques des variables par des libellés plus explicites.

Code

Les noms techniques des variables sont remplacés par des libellés plus faciles à comprendre.

```
statistiques_descriptives$Variable <- c(  
  "Population desservie",  
  "Nombre de succursales",  
  "Heures d'ouverture",  
  "Superficie",  
  "Ratio abonnés/population",  
  "Indice de ressources technologiques"  
)
```


Résultats

Les variables sont présentées avec des libellés plus faciles à interpréter.

Analyse

Cette modification concerne uniquement la présentation du tableau et n'affecte pas les résultats.

2.5 Affichage du tableau des statistiques descriptives

Objectif

Présenter le tableau final des statistiques descriptives.

Code

Le tableau des statistiques descriptives est affiché.

```
statistiques_descriptives
```

Résultats

Le tableau présente les principales statistiques descriptives des six variables analysées.

	Variable	N	Moyenne	Mediane	Ecart_type	Minimum
Maximum						
1	Population desservie	295	48104.95	6588.00	197522.49	48.00
2956024.00						
2	Nombre de succursales	295	3.12	1.00	6.96	1.00
100.00						
3	Heures d'ouverture	295	120.02	42.50	370.85	5.00
5697.75						
4	Superficie	258	31197.93	6547.50	127371.45	118.00
1883890.00						
5	Ratio abonnés/population	295	0.32	0.24	0.29	0.00
2.21						
6	Indice de ressources technologiques	294	0.00	-0.19	0.61	-0.26
4.98						

Analyse

Les statistiques descriptives montrent une grande variabilité entre les bibliothèques étudiées. La population desservie, la superficie et les heures d'ouverture présentent des écarts importants entre leurs valeurs minimales et maximales. Pour ces variables, la moyenne est également nettement supérieure à la médiane, ce qui

indique des distributions asymétriques influencées par quelques valeurs très élevées. Cette asymétrie sera examinée plus directement à l'aide des visualisations de la section suivante.

Le ratio abonnés/population présente une moyenne de 0,32 et une médiane de 0,24. Ces valeurs correspondent à la distribution des ratios calculés pour chaque bibliothèque et ne doivent pas être interprétées comme un taux global d'abonnement pour l'ensemble de la population ontarienne.

L'indice de ressources technologiques présente une moyenne proche de 0, ce qui est cohérent avec sa construction à partir de variables standardisées. Sa médiane de -0,19 et son maximum de 4,98 indiquent une distribution asymétrique. La majorité des bibliothèques présentent des valeurs relativement faibles, tandis que quelques bibliothèques obtiennent des indices beaucoup plus élevés.

SECTION 3 : VISUALISATIONS DESCRIPTIVES

Cette section permet d'examiner visuellement la distribution des principales variables étudiées et les relations entre elles. Des histogrammes et des boîtes à moustaches sont d'abord utilisés pour observer leur répartition, leur asymétrie et la présence de valeurs extrêmes. Des matrices de nuages de points permettent ensuite d'examiner simultanément les relations entre les variables, avant et après transformation logarithmique.

3.1 Préparation des libellés

Objectif

Préparer des libellés courts et explicites pour les graphiques.

Code

Un vecteur contenant les libellés des variables est créé.

```
libelles_variables <- c(
  "Population desservie",
  "Nombre de succursales",
  "Heures d'ouverture",
  "Superficie",
  "Ratio abonnés/population",
  "Indice technologique"
)
```

Résultats

Les six libellés sont créés et enregistrés dans un vecteur.

Analyse

Cette étape facilite la lecture des graphiques sans modifier les données analysées.

3.2 Histogrammes

Objectif

Examiner la distribution et l'asymétrie des six variables étudiées.

Code

Une nouvelle fenêtre est divisée en six espaces.

```
dev.new()
par(mfrow = c(2, 3))
```

Une boucle permet de produire successivement les six graphiques. Les libellés préparés à la section 3.1 sont utilisés pour identifier chaque variable.

```
for (i in 1:length(variables_analyse)) {
  variable <- variables_analyse[i]
  valeurs <- donnees[[variable]]

  hist(
    valeurs,
    main = libelles_variables[i],
    xlab = libelles_variables[i],
    ylab = "Nombre de bibliothèques"
  )
}
```

Résultats

La figure 1 présente les histogrammes des six variables retenues.




Figure 1. Histogrammes des variables analysées

Analyse

Les histogrammes montrent que plusieurs variables présentent une forte asymétrie vers la droite, particulièrement la population desservie, le nombre de succursales, les heures d'ouverture, la superficie et l'indice technologique.

Le ratio abonnés/population est moins asymétrique, mais présente également quelques valeurs élevées.

Ces résultats confirment les écarts observés entre les moyennes et les médianes et justifient l'examen de transformations logarithmiques dans les analyses suivantes.

3.3 Boîtes à moustaches

Objectif

Examiner la dispersion des variables et repérer les valeurs qui se distinguent du reste des observations.

Code

Une deuxième fenêtre est divisée en six espaces.

```
dev.new()
par(mfrow = c(2, 3))
```

Une boucle produit une boîte à moustaches pour chaque variable.

```
for (i in 1:length(variables_analyse)) {
  variable <- variables_analyse[i]
  valeurs <- donnees[[variable]]

  boxplot(
    valeurs,
    main = libelles_variables[i],
    ylab = libelles_variables[i]
  )
}
```

Résultats

La figure 2 présente les boîtes à moustaches des six variables retenues.




Figure 2. Boîtes à moustaches des variables analysées

Analyse

Les boîtes à moustaches confirment la présence de nombreuses valeurs extrêmes. Ces observations sont conservées puisqu'elles reflètent la diversité des bibliothèques étudiées, mais elles pourraient exercer une influence importante sur certaines analyses statistiques.

3.4 Matrice de nuages de points

Objectif

Visualiser simultanément les relations entre les principales variables utilisées dans les analyses.

Code

Les six variables sont regroupées dans un même tableau.

```
donnees_visualisation <- donnees[, variables_analyse]
```

Une matrice de nuages de points est produite.

```
pairs(  
  donnees_visualisation,  
  labels = libelles_variables,  
  cex = 0.5,  
  main = "Relations entre les principales variables"  
)
```

Résultats

La figure 3 présente les relations entre les six principales variables.




Figure 3 : Matrice de nuages de points entre les principales variables

Analyse

La matrice montre que plusieurs variables liées à la taille des bibliothèques évoluent ensemble, notamment la population desservie, les heures d'ouverture, le nombre de succursales et la superficie. Les relations avec le ratio abonnés/population et l'indice technologique sont moins évidentes.

La forte asymétrie des variables concentre toutefois une grande partie des observations dans les faibles valeurs, ce qui limite la lisibilité de certaines relations. Une transformation logarithmique est donc examinée dans la section suivante.

3.5 Matrice après transformation logarithmique

Objectif

Visualiser simultanément les relations entre les principales variables après transformation logarithmique des variables asymétriques.

Code

La population desservie, le nombre de succursales, les heures d'ouverture, la superficie et le ratio abonnés/population sont transformés en logarithme de base 10. L'indice technologique est conservé dans son échelle originale.

```
donnees_visualisation_log <- data.frame(  
  Population = log10(donnees$Population_desservie),  
  Succursales = log10(donnees$Nb_succursales),  
  Heures_ouverture = log10(donnees$Heures_ouverture),  
  Superficie = log10(donnees$Superficie),  
  Ratio_abonnes = log10(donnees$Ratio_abonnes_population),  
  Indice_technologique = donnees$Indice_ressources_technologiques  
)
```

Une nouvelle matrice de nuages de points est produite.

```
pairs(  
  donnees_visualisation_log,  
  labels = libelles_variables,  
  cex = 0.5,  
  main = "Relations après transformation logarithmique"  
)
```


Résultats

La figure 4 présente les relations entre les variables après transformation logarithmique.




Figure 4 : Matrice de nuages de points après transformation logarithmique

Analyse

La transformation logarithmique répartit davantage les observations et rend plusieurs relations plus visibles. La population, les heures d'ouverture, le nombre de succursales et la superficie apparaissent fortement liées entre elles, ce qui suggère qu'elles décrivent en partie une même dimension liée à la taille des bibliothèques.

Le ratio abonnés/population demeure beaucoup moins lié à ces variables. Les relations avec l'indice technologique deviennent également plus faciles à examiner, ce qui prépare les analyses de corrélation de la section suivante.

SECTION 4 : CORRÉLATIONS LINÉAIRES DE PEARSON

Cette section examine les relations linéaires entre l'indice de ressources technologiques et les principales caractéristiques des bibliothèques. Les relations sont d'abord représentées par des nuages de points, puis évaluées à l'aide du coefficient de corrélation de Pearson. La valeur p et le coefficient de détermination (R^2) complètent l'analyse afin de distinguer la significativité statistique de l'importance des relations observées.

4.1 Préparation des variables

Objectif

Préparer les variables et les libellés qui seront utilisés dans les analyses de corrélation et la production des graphiques.

Code

Les cinq variables explicatives sont regroupées dans une liste.

```
variables_x <- list(  
  donnees$Population_desservie,  
  donnees$Heures_ouverture,  
  donnees$Nb_succursales,  
  donnees$Superficie,  
  donnees$Ratio_abonnes_population  
)
```

Un vecteur est créé pour nommer les cinq relations étudiées et identifier les graphiques.

```
noms_relations <- c(  
  "Population desservie",  
  "Heures d'ouverture",  
  "Nombre de succursales",  
  "Superficie",  
  "Ratio abonnés/population"  
)
```

L'indice technologique est enregistré séparément puisqu'il sera comparé à chacune des cinq variables.

```
indice <- donnees$Indice_ressources_technologiques
```

Résultats

Les variables et les libellés nécessaires aux cinq analyses de corrélation sont préparés.

Analyse

Cette préparation permet d'appliquer la même procédure aux cinq relations étudiées.

4.2 Nuages de points

Objectif

Visualiser les relations entre chacune des variables explicatives et l'indice de ressources technologiques avant de calculer les corrélations.

Code

Une nouvelle fenêtre est divisée en six espaces.

```
dev.new()  
par(mfrow = c(2, 3))
```

Une boucle parcourt ensuite chacune des variables explicatives et produit un nuage de points représentant sa relation avec l'indice de ressources technologiques.

```
for (i in 1:length(variables_x)) {  
  plot(  
    variables_x[[i]],  
    indice,  
    main = noms_relations[i],  
    xlab = noms_relations[i],  
    ylab = "Indice technologique",  
    pch = 20,  
    col = "blue"  
  )  
}
```

Résultats

La figure 5 présente les cinq nuages de points illustrant la relation entre chacune des variables explicatives et l'indice de ressources technologiques.




Figure 5. Nuages de points entre les variables explicatives et l'indice de ressources technologiques

Analyse

Les nuages de points montrent une forte concentration des observations dans les faibles valeurs et quelques observations beaucoup plus élevées, ce qui est cohérent avec l'asymétrie observée précédemment.

Aucune relation linéaire claire ne se dégage pour la population desservie, les heures d'ouverture, le nombre de succursales ou la superficie. Le ratio abonnés/population présente une légère tendance positive, mais les observations demeurent très dispersées.

4.3 Calcul des corrélations de Pearson

Objectif

Calculer les corrélations de Pearson entre chacune des variables étudiées et l'indice de ressources technologiques, puis enregistrer les résultats dans un tableau.

Code

Un tableau est créé pour enregistrer les résultats des cinq corrélations.

```
tableau_correlations <- data.frame(  
  Relation = noms_relations,  
  N = numeric(length(variables_x)),  
  Coefficient = numeric(length(variables_x)),  
  Valeur_p = numeric(length(variables_x)),  
  R_carre = numeric(length(variables_x))  
)
```

Une boucle réalise ensuite le test de corrélation de Pearson pour chaque variable.

```
for (i in 1:length(variables_x)) {  
  variable <- variables_x[[i]]  
  test_correlation <- cor.test(variable, indice)
```

Les résultats sont ajoutés au tableau. Le nombre d'observations complètes est calculé séparément et le R^2 correspond au carré du coefficient de corrélation.

```
tableau_correlations$N[i] <- sum(complete.cases(variable, indice))  
tableau_correlations$Coefficient[i] <- test_correlation$estimate  
tableau_correlations$Valeur_p[i] <- test_correlation$p.value  
tableau_correlations$R_carre[i] <- test_correlation$estimate^2  
}
```

Résultats

Les corrélations de Pearson ont été calculées pour les cinq relations étudiées. Le tableau obtenu contient, pour chacune d'elles, le nombre d'observations complètes, le coefficient de corrélation, la valeur p et le coefficient de détermination. Les résultats sont présentés à la section suivante.

Analyse

Le coefficient indique la direction et l'intensité de la relation linéaire, tandis que la valeur p permet d'en évaluer la significativité statistique. Le R^2 complète l'analyse en donnant une indication de l'importance de la relation observée.

4.4 Tableau récapitulatif des corrélations

Objectif

Présenter et interpréter les résultats des corrélations de Pearson.

Code

Les coefficients et les R^2 sont arrondis à trois décimales.

```
tableau_correlations$Coefficient <-  
  round(tableau_correlations$Coefficient, 3)  
  
tableau_correlations$R_carre <-  
  round(tableau_correlations$R_carre, 3)
```

Les valeurs p inférieures à 0,001 sont présentées sous la forme « < 0.001 ».

```
tableau_correlations$Valeur_p <-  
  ifelse(  
    tableau_correlations$Valeur_p < 0.001,  
    "< 0.001",  
    round(tableau_correlations$Valeur_p, 3)  
  )
```

Résultats

Le tableau récapitulatif des corrélations de Pearson est présenté ci-dessous.

```
tableau_correlations  
      Relation      N Coefficient Valeur_p R_carre  
1 Population desservie 294      -0.088    0.13  0.008  
2 Heures d'ouverture 294      -0.088    0.133  0.008  
3 Nombre de succursales 294     -0.094    0.108  0.009  
4 Superficie 257      -0.072    0.247  0.005  
5 Ratio abonnés/population 294     0.222 < 0.001  0.049
```

Analyse

Les corrélations de Pearson montrent que les relations linéaires entre l'indice de ressources technologiques et les variables étudiées sont faibles ou très faibles.

Le ratio abonnés/population présente la relation la plus élevée avec l'indice technologique ($r = 0,222$). Cette relation est positive et statistiquement significative ($p < 0,001$), mais elle demeure faible. Son R^2 de 0,049 indique que la relation linéaire ne rend compte que d'environ 4,9 % de la variation observée.

Les quatre autres variables présentent des corrélations négatives très faibles, comprises entre $-0,072$ et $-0,094$. Aucune de ces relations n'est statistiquement significative ($p > 0,05$), et leurs R^2 sont tous inférieurs à 0,01.

Ces résultats doivent toutefois être interprétés avec prudence. La population desservie intervient directement dans le calcul de l'indice technologique et du ratio abonnés/population. Les relations concernant ces variables sont donc exploratoires et seront approfondies dans les analyses multivariées.

Enfin, plusieurs variables présentent une forte asymétrie et quelques valeurs très élevées. La section suivante examine donc les mêmes relations après transformation logarithmique afin de vérifier si celles-ci apparaissent plus clairement.

SECTION 5 : CORRÉLATIONS DE PEARSON APRÈS TRANSFORMATION LOGARITHMIQUE

Cette section reprend les corrélations de Pearson après avoir appliqué une transformation logarithmique aux variables explicatives. Les analyses précédentes ont montré que plusieurs variables présentent une forte asymétrie et quelques valeurs très élevées. La transformation logarithmique permet de réduire cette asymétrie et de vérifier si les relations linéaires apparaissent plus clairement.

5.1 Préparation des variables

Objectif

Transformer les variables explicatives à l'aide d'une transformation logarithmique en base 10 et préparer les libellés qui seront utilisés dans les analyses de corrélation et la production des graphiques.

Code

Les cinq variables explicatives sont transformées à l'aide d'un logarithme en base 10, puis regroupées dans une liste.

```
variables_x_log <- list(  
  log10(donnees$Population_desservie),  
  log10(donnees$Heures_ouverture),  
  log10(donnees$Nb_succursales),  
  log10(donnees$Superficie),  
  log10(donnees$Ratio_abonnes_population)  
)
```

Un vecteur est également créé pour identifier les relations dans le tableau de résultats.

```
noms_relations_log <- c(  
  "Population desservie (log10)",  
  "Heures d'ouverture (log10)",  
  "Nombre de succursales (log10)",  
  "Superficie (log10)",  
  "Ratio abonnés/population (log10)"  
)
```


Résultats

Les cinq variables explicatives sont transformées en logarithme de base 10 et préparées pour les analyses.

Analyse

La transformation logarithmique atténue l'influence des valeurs très élevées et permet de mieux répartir les observations. Elle est pertinente pour les variables dont les distributions étaient fortement asymétriques.

5.2 Nuages de points

Objectif

Visualiser les relations entre chacune des variables transformées et l'indice de ressources technologiques.

Code

Une nouvelle fenêtre est divisée en six espaces.

```
dev.new()
par(mfrow = c(2, 3))
```

Une boucle produit ensuite les cinq nuages de points.

```
for (i in 1:length(variables_x_log)) {
  plot(
    variables_x_log[[i]],
    indice,
    main = noms_relations[i],
    xlab = noms_relations[i],
    ylab = "Indice technologique",
    pch = 20,
    col = "blue"
  )
}
```

Résultats

La figure 6 présente les cinq nuages de points après transformation logarithmique.




Figure 6. Nuages de points entre les variables explicatives transformées (log10) et l'indice de ressources technologiques.

Analyse

La transformation logarithmique répartit davantage les observations sur l'axe horizontal et rend les nuages de points plus lisibles.

Une tendance négative apparaît plus clairement pour la population desservie, les heures d'ouverture, le nombre de succursales et la superficie. Le ratio abonnés/population conserve une légère tendance positive.

5.3 Calcul des corrélations de Pearson

Objectif

Calculer les corrélations de Pearson entre chacune des variables transformées et l'indice de ressources technologiques, puis enregistrer les résultats dans un tableau.

Code

Un tableau est créé pour enregistrer les résultats des cinq corrélations.

```
tableau_correlations_log <- data.frame(  
  Relation = noms_relations_log,  
  N = numeric(length(variables_x_log)),  
  Coefficient = numeric(length(variables_x_log)),  
  Valeur_p = numeric(length(variables_x_log)),  
  R_carre = numeric(length(variables_x_log))  
)
```

Une boucle réalise le test de corrélation de Pearson pour chaque variable transformée.

```
for (i in 1:length(variables_x_log)) {  
  variable <- variables_x_log[[i]]  
  test_correlation <- cor.test(variable, indice)
```

Les résultats sont ajoutés au tableau. Le nombre d'observations complètes est calculé séparément et le R^2 correspond au carré du coefficient de corrélation.

```
tableau_correlations_log$N[i] <- sum(complete.cases(variable,  
  indice))  
  
tableau_correlations_log$Coefficient[i] <-  
  test_correlation$estimate  
  
tableau_correlations_log$Valeur_p[i] <- test_correlation$p.value  
  
tableau_correlations_log$R_carre[i] <- test_correlation$estimate^2  
}
```

Résultats

Les cinq corrélations sont calculées. Les résultats sont présentés dans le tableau de la section suivante.

Analyse

Cette analyse permet de comparer les relations obtenues après transformation logarithmique avec celles calculées sur les données originales.

5.4 Tableau récapitulatif des corrélations

Objectif

Présenter les résultats des corrélations de Pearson après transformation logarithmique dans un tableau clair et facile à interpréter.

Code

Les résultats sont arrondis afin d'en faciliter la lecture.

```
tableau_correlations_log$Coefficient <-  
  round(tableau_correlations_log$Coefficient, 3)  
  
tableau_correlations_log$R_carre <-  
  round(tableau_correlations_log$R_carre, 3)
```

Les valeurs p inférieures à 0,001 sont ensuite remplacées par l'expression « < 0.001 », tandis que les autres sont arrondies à trois décimales.

```
tableau_correlations_log$Valeur_p <-  
  ifelse(  
    tableau_correlations_log$Valeur_p < 0.001,  
    "< 0.001",  
    round(tableau_correlations_log$Valeur_p, 3)  
  )
```

Résultats

Le tableau récapitulatif des corrélations de Pearson après transformation logarithmique est présenté ci-dessous.

		Relation	N	Coefficient	Valeur_p	R_carre
1	Population desservie	(log10)	294	-0.496	< 0.001	0.246
2	Heures d'ouverture	(log10)	294	-0.236	< 0.001	0.056
3	Nombre de succursales	(log10)	294	-0.184	0.002	0.034
4	Superficie	(log10)	257	-0.312	< 0.001	0.097
5	Ratio abonnés/population	(log10)	294	0.126	0.03	0.016

Analyse

Après transformation logarithmique, les relations apparaissent plus clairement. La population desservie présente la relation la plus forte avec l'indice technologique ($r = -0,496$), suivie de la superficie ($r = -0,312$). Les heures d'ouverture et le nombre

de succursales présentent des relations négatives plus faibles, tandis que le ratio abonnés/population conserve une faible relation positive ($r = 0,126$).

Toutes ces relations sont statistiquement significatives, mais leur importance demeure généralement faible à modérée. La relation avec la population est la plus marquée, avec un R^2 de 0,246, tandis que les autres R^2 demeurent inférieurs à 0,10.

La relation avec la population doit être interprétée avec prudence, puisque celle-ci intervient directement dans le calcul de l'indice technologique. Les corrélations demeurent des analyses bivariées, puisqu'elles examinent chaque variable séparément.

La section suivante utilise donc une régression linéaire multiple afin d'examiner simultanément plusieurs caractéristiques des bibliothèques et de mieux distinguer leurs relations avec l'indice technologique.

SECTION 6 : RÉGRESSION LINÉAIRE MULTIPLE

Les corrélations précédentes examinaient séparément chaque caractéristique des bibliothèques. La régression linéaire multiple permet maintenant d'étudier ces caractéristiques simultanément et leur relation avec l'indice technologique.

6.1 Préparation des données

Objectif

Préparer les variables utilisées dans la régression linéaire multiple.

Code

Un tableau est créé avec l'indice technologique et les cinq variables étudiées précédemment. Les transformations logarithmiques de la section 5 sont conservées.

```
donnees_regression <- data.frame(  
  Nom_bibliotheque = donnees$Nom_bibliotheque,  
  Indice_technologique = donnees$Indice_ressources_technologiques,  
  Population_log = log10(donnees$Population_desservie),  
  Heures_ouverture_log = log10(donnees$Heures_ouverture),  
  Succursales_log = log10(donnees$Nb_succursales),  
  Superficie_log = log10(donnees$Superficie),  
  Ratio_abonnes_log = log10(donnees$Ratio_abonnes_population)  
)
```

Seulement les observations complètes sont retenues.

```
donnees_regression <-  
  donnees_regression[complete.cases(donnees_regression),]
```

Résultats

Le tableau contient 257 bibliothèques.

```
dim(donnees_regression)  
[1] 257 7
```

Analyse

Les 38 bibliothèques exclues présentent au moins une valeur manquante parmi les variables du modèle. Cette différence s'explique principalement par les valeurs manquantes de la superficie.

6.2 Modèle initial

Objectif

Examiner simultanément la relation entre les cinq caractéristiques étudiées et l'indice technologique.

Code

La fonction `lm()` est utilisée pour construire le modèle. L'indice technologique constitue la variable à expliquer et les cinq caractéristiques des bibliothèques sont utilisées comme variables explicatives.

```
modele_initial <- lm(
  Indice_technologique ~
    Population_log +
    Heures_ouverture_log +
    Succursales_log +
    Superficie_log +
    Ratio_abonnes_log,
  data = donnees_regression
)
```

Résultats

Le modèle est statistiquement significatif ($p < 0,001$) et son R^2 ajusté est de 0,337. La population, les heures d'ouverture et la superficie présentent une relation significative avec l'indice technologique. Le nombre de succursales et le ratio abonnés/population ne sont pas significatifs.

```
summary(modele_initial)

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    0.92342    0.24283   3.803  0.00018 ***
Population_log -0.80219    0.09192  -8.727 3.71e-16 ***
Heures_ouverture_log 0.49590    0.17620   2.814  0.00527 **
Succursales_log -0.08083    0.15665  -0.516  0.60631
Superficie_log   0.35856    0.11281   3.178  0.00167 **
Ratio_abonnes_log  0.05769    0.09822   0.587  0.55753
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.478 on 251 degrees of freedom
Multiple R-squared:  0.3498,    Adjusted R-squared:  0.3368
F-statistic: 27 on 5 and 251 DF,  p-value: < 2.2e-16
```

Analyse

Le modèle explique environ 34 % de la variation de l'indice technologique. La population présente la relation négative la plus marquée, tandis que les heures d'ouverture et la superficie présentent des relations positives lorsque les autres variables sont maintenues constantes.

Les fortes relations entre certaines variables explicatives peuvent compliquer l'interprétation de leurs coefficients. Ces relations sont donc examinées dans la section suivante.

6.3 Corrélations entre les variables explicatives

Objectif

Vérifier si certaines variables explicatives sont fortement liées entre elles.

Code

Les cinq variables explicatives sont regroupées dans un tableau.

```
variables_regression <- donnees_regression[  
  ,  
  c(  
    "Population_log",  
    "Heures_ouverture_log",  
    "Succursales_log",  
    "Superficie_log",  
    "Ratio_abonnes_log"  
  )  
]
```

La matrice de corrélation est ensuite calculée et arrondie à trois décimales.

```
correlations_regression <- cor(variables_regression)  
round(correlations_regression, 3)
```


Résultats

La matrice de corrélation montre que plusieurs variables décrivant la taille des bibliothèques sont liées entre elles. La population desservie, les heures d'ouverture, le nombre de succursales et la superficie présentent des corrélations positives importantes.

Le ratio abonnés/population présente des relations plus faibles avec les caractéristiques liées à la taille des bibliothèques.

	Population_log	Heures_ouverture_log	Succursales_log
Population_log	1.000	0.815	0.655
Heures_ouverture_log	0.815	1.000	0.858
Succursales_log	0.655	0.858	1.000
Superficie_log	0.895	0.838	0.695
Ratio_abonnes_log	-0.145	0.038	0.024
	Superficie_log	Ratio_abonnes_log	
Population_log	0.895	-0.145	
Heures_ouverture_log	0.838	0.038	
Succursales_log	0.695	0.024	
Superficie_log	1.000	0.024	
Ratio_abonnes_log	0.024	1.000	

Analyse

Plusieurs variables explicatives apportent une information similaire sur la taille des bibliothèques. Leur présence simultanée dans le modèle pourrait compliquer l'interprétation de leurs relations respectives avec l'indice technologique.

La matrice de corrélation ne suffit pas à évaluer leur effet combiné dans le modèle. La multicolinéarité est examinée plus directement à l'aide du facteur d'inflation de la variance (VIF) dans la section suivante.

6.4 Vérification de la multicolinéarité

Objectif

Vérifier la présence de multicolinéarité entre les variables explicatives à l'aide du VIF.

Code

Un vecteur est créé pour recevoir les cinq VIF.

```
vif_initial <- numeric(5)
```

Pour chaque variable, une régression avec les quatre autres variables permet de calculer son VIF.

```
for (i in 1:5) {  
  variable_y <- variables_regression[, i]  
  autres_variables <- variables_regression[, -i]  
  modele_vif <- lm(variable_y ~ ., data = autres_variables)  
  r_carre <- summary(modele_vif)$r.squared  
  vif_initial[i] <- 1 / (1 - r_carre)  
}
```

Les noms des variables sont associés aux résultats et les VIF sont arrondis à deux décimales.

```
names(vif_initial) <- names(variables_regression)  
round(vif_initial, 2)
```

Résultats

Les VIF confirment que certaines variables du modèle initial partagent une part importante de leur information. Les valeurs les plus élevées concernent les variables associées à la taille des bibliothèques, ce qui concorde avec les corrélations observées à la section précédente.

Population_log	Heures_ouverture_log	Succursales_log
6.54	7.34	3.89
Superficie_log	Ratio_abonnes_log	
6.56	1.19	

Analyse

La présence de multicollinéarité complique l'interprétation de la relation propre à chaque variable avec l'indice technologique lorsqu'elles sont incluses simultanément dans le modèle.

Ces résultats, ainsi que la présence de la population dans le calcul de l'indice technologique, justifient la recherche d'un modèle final plus simple.

Le modèle sans population est examiné dans la section suivante.

6.5 Modèle sans la population

Objectif

Examiner le modèle sans la population, **puisque** elle intervient dans le calcul de l'indice technologique.

Code

Un nouveau modèle est construit avec les quatre autres variables explicatives.

```
modele_sans_population <- lm(
  Indice_technologique ~
    Heures_ouverture_log +
    Succursales_log +
    Superficie_log +
    Ratio_abonnes_log,
  data = donnees_regression
)
```

Les variables explicatives sont ensuite regroupées afin de vérifier à nouveau la multicollinéarité.

```
variables_sans_population <- donnees_regression[
  ,
  c(
    "Heures_ouverture_log",
    "Succursales_log",
    "Superficie_log",
    "Ratio_abonnes_log"
  )
]

vif_sans_population <- numeric(4)
```

Les VIF sont calculés de la même façon que pour le modèle initial.

```
for (i in 1:4) {  
  variable_y <- variables_sans_population[, i]  
  autres_variables <- variables_sans_population[, -i]  
  modele_vif <- lm(variable_y ~ ., data = autres_variables)  
  r_carre <- summary(modele_vif)$r.squared  
  vif_sans_population[i] <- 1 / (1 - r_carre)  
}  
names(vif_sans_population) <- names(variables_sans_population)  
round(vif_sans_population, 2)
```

Résultats

Le modèle demeure significatif ($p < 0,001$), avec un R^2 ajusté de 0,139. La superficie et le ratio abonnés/population sont significatifs, contrairement aux heures d'ouverture et au nombre de succursales.

```
summary(modele_sans_population)  
  
Coefficients:  
              Estimate Std. Error t value Pr(>|t|)  
(Intercept)    1.41770    0.26906   5.269 2.94e-07 ***  
Heures_ouverture_log  0.01668    0.19076   0.087 0.930379  
Succursales_log     0.11146    0.17671   0.631 0.528797  
Superficie_log     -0.32696    0.09226  -3.544 0.000470 ***  
Ratio_abonnes_log   0.40134    0.10253   3.914 0.000117 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
Residual standard error: 0.5446 on 252 degrees of freedom  
Multiple R-squared:  0.1525,    Adjusted R-squared:  0.139  
F-statistic: 11.33 on 4 and 252 DF,  p-value: 1.79e-08
```

Les VIF obtenus sont de 6,62 pour les heures d'ouverture, 3,81 pour le nombre de succursales, 3,38 pour la superficie et 1,00 pour le ratio abonnés/population.

Heures_ouverture_log	Succursales_log	Superficie_log
6.62	3.81	3.38
Ratio_abonnes_log		
1.00		

Analyse

Le retrait de la population évite d'utiliser une variable qui intervient dans le calcul de l'indice. La multicollinéarité demeure présente, surtout pour les heures d'ouverture. La superficie et le ratio abonnés/population ressortent comme les variables les plus pertinentes pour construire un modèle final plus simple.

6.6 Modèle retenu

Objectif

Construire un modèle plus simple avec les deux variables significatives du modèle sans population.

Code

Le modèle retenu utilise la superficie et le ratio abonnés/population.

```
modele_regression <- lm(
  Indice_technologique ~
    Superficie_log +
    Ratio_abonnes_log,
  data = donnees_regression
)
```

La relation entre les deux variables explicatives est également vérifiée.

```
cor(
  donnees_regression$Superficie_log,
  donnees_regression$Ratio_abonnes_log
)
```

Résultats

Le modèle est statistiquement significatif ($p < 0,001$), avec un R^2 de 0,149 et un R^2 ajusté de 0,143.

```
summary(modele_regression)

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    1.27399    0.20819   6.119 3.54e-09 ***
Superficie_log -0.27462    0.05008  -5.483 1.01e-07 ***
Ratio_abonnes_log 0.40264    0.10225   3.938 0.000106 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5435 on 254 degrees of freedom
Multiple R-squared:  0.1493,    Adjusted R-squared:  0.1426
F-statistic: 22.28 on 2 and 254 DF,  p-value: 1.212e-09
```

La superficie présente une relation négative significative avec l'indice technologique ($p < 0,001$), tandis que le ratio abonnés/population présente une relation positive significative ($p < 0,001$).

La corrélation entre les deux variables explicatives est presque nulle ($r = 0,024$).

```
[1] 0.02386848
```

Analyse

Le modèle retenu explique environ 14 % de la variation de l'indice technologique. Une superficie plus élevée est associée à un indice plus faible, tandis qu'un ratio abonnés/population plus élevé est associé à un indice plus élevé.

Les deux variables sont très peu corrélées entre elles, ce qui réduit le problème de multicollinéarité observé dans les modèles précédents. Le modèle est plus simple et permet d'interpréter plus clairement les deux relations retenues.

6.7 Validation graphique du modèle

Objectif

Vérifier graphiquement les principales conditions du modèle et repérer d'éventuelles observations atypiques.

Code

Les quatre graphiques diagnostiques produits par R sont affichés.

```
par(mfrow = c(2, 2))  
plot(modele_regression)
```

Résultats

La figure 7 présente les quatre graphiques diagnostiques du modèle.




Figure 7 : Graphiques diagnostiques du modèle de régression linéaire multiple

Analyse

Les graphiques montrent que le modèle présente certaines limites. Les résidus ne sont pas répartis de façon parfaitement uniforme et le graphique Q-Q s'éloigne de la ligne droite dans les valeurs élevées. La dispersion des résidus augmente également pour certaines valeurs prédites.

Quelques observations se distinguent fortement des autres et pourraient exercer une influence importante sur les résultats. Le modèle doit donc être interprété avec prudence.

6.8 Tableau des résultats de la régression

Objectif

Présenter les coefficients du modèle de régression retenu.

Code

Les coefficients du modèle sont extraits.

```
tableau_regression <- as.data.frame(summary(modele_regression)$coefficients)
```

Les noms des variables sont ajoutés et les colonnes sont réorganisées.

```
tableau_regression$Variable <- row.names(tableau_regression)

tableau_regression <- tableau_regression[
  ,
  c("Variable", "Estimate", "Std. Error", "t value", "Pr(>|t|)")
]
```

Résultats

Le tableau présente les coefficients, les erreurs standards, les valeurs t et les valeurs p du modèle retenu.

```
tableau_regression
              Variable      Estimate Std. Error    t value
(Intercept)      (Intercept)  1.2739900  0.20819114   6.119329
Superficie_log    Superficie_log -0.2746154  0.05008333  -5.483169
Ratio_abonnes_log Ratio_abonnes_log  0.4026440  0.10224702   3.937953
              Pr(>|t|)
(Intercept)    3.538390e-09
Superficie_log  1.007538e-07
Ratio_abonnes_log 1.062058e-04
```

Analyse

Le modèle retenu confirme que les deux variables sont significativement associées à l'indice technologique. La superficie présente une relation négative, tandis que le ratio abonnés/population présente une relation positive.

Ces résultats complètent les analyses précédentes avec un modèle plus simple et moins touché par la multicolinéarité. Ils doivent toutefois être interprétés avec prudence en raison des limites observées dans les graphiques diagnostiques.

SECTION 7 : ANALYSE EN COMPOSANTES PRINCIPALES

L'analyse en composantes principales (ACP) permet d'examiner simultanément plusieurs caractéristiques des bibliothèques afin de faire ressortir les principales dimensions qui structurent les données.

7.1 Préparation des données

Objectif

Préparer les variables utilisées dans l'ACP.

Code

Les cinq variables transformées utilisées précédemment dans les analyses sont sélectionnées.

```
donnees_acp <- donnees_regression[
  ,
  c(
    "Population_log",
    "Heures_ouverture_log",
    "Succursales_log",
    "Superficie_log",
    "Ratio_abonnes_log"
  )
]
```

Résultats

Le jeu de données préparé pour l'ACP contient cinq caractéristiques des bibliothèques : la population desservie, les heures d'ouverture, le nombre de succursales, la superficie et le ratio abonnés/population.

Analyse

Les versions transformées en logarithme sont utilisées afin de réduire l'effet des distributions fortement asymétriques.

Elles serviront à déterminer si certaines dimensions communes permettent de résumer l'information contenue dans les données.

7.2 Réalisation de l'ACP

Objectif

Réaliser l'ACP et déterminer l'importance des composantes obtenues.

Code

L'ACP est réalisée avec des variables centrées et standardisées.

```
acp <- prcomp(  
  donnees_acp,  
  center = TRUE,  
  scale. = TRUE  
)
```

Résultats

La première composante explique 67,64 % de la variance et la deuxième 20,57 %.

Ensemble, elles en expliquent 88,21 %.

```
summary(acp)  
  
Importance of components:  
  
          PC1      PC2      PC3      PC4      PC5  
Standard deviation  1.8389  1.0142  0.63642  0.31496  0.29233  
Proportion of Variance 0.6764  0.2057  0.08101  0.01984  0.01709  
Cumulative Proportion 0.6764  0.8821  0.96307  0.98291  1.00000
```

Analyse

Les deux premières composantes résument une grande partie de l'information contenue dans les cinq variables. Elles sont retenues pour représenter les bibliothèques.

7.3 Interprétation des composantes

Objectif

Présenter la contribution des variables aux composantes principales afin de faciliter leur interprétation.

Code

Les coefficients des variables sont extraits et regroupés dans un tableau. Le signe de la deuxième composante est inversé afin de faciliter son interprétation.

```
tableau_composantes_acp <- as.data.frame(acp$rotation)

tableau_composantes_acp$PC2 <- -tableau_composantes_acp$PC2

tableau_composantes_acp$Variable <- row.names(tableau_composantes_acp)

tableau_composantes_acp <- tableau_composantes_acp[
  ,
  c("Variable", "PC1", "PC2", "PC3", "PC4", "PC5")
]

tableau_composantes_acp[, 2:6] <-
  round(tableau_composantes_acp[, 2:6], 3)

tableau_composantes_acp
```

Résultats

Ce tableau présente les coefficients des cinq variables pour chacune des composantes principales.

	Variable	PC1	PC2	PC3	PC4	PC5
Population_log	Population_log	0.499	-0.157	-0.467	0.171	-0.692
Heures_ouverture_log	Heures_ouverture_log	0.519	0.073	0.203	0.724	0.399
Succursales_log	Succursales_log	0.472	0.081	0.731	-0.403	-0.270
Superficie_log	Superficie_log	0.508	0.028	-0.433	-0.532	0.520
Ratio_abonnes_log	Ratio_abonnes_log	-0.012	0.981	-0.138	0.022	-0.133

Analyse

PC1 est principalement associée à la population, aux heures d'ouverture, au nombre de succursales et à la superficie. Elle représente donc la taille du réseau.

PC2 est presque entièrement associée au ratio abonnés/population et représente le ratio d'abonnés.

7.4 Représentation des bibliothèques

Objectif

Représenter les bibliothèques selon les deux premières composantes principales.

Code

Les coordonnées des bibliothèques sont extraites à partir de l'ACP. Le signe de la deuxième composante est inversé afin de faciliter son interprétation.

```
coordonnees_acp <- acp$x  
coordonnees_acp[, 2] <- -coordonnees_acp[, 2]
```

Un tableau est ensuite créé avec le nom de chaque bibliothèque et ses coordonnées sur les deux premières composantes.

```
tableau_coordonnees_acp <- data.frame(  
  Nom_bibliotheque = donnees_regression$Nom_bibliotheque,  
  PC1 = coordonnees_acp[, 1],  
  PC2 = coordonnees_acp[, 2]  
)
```

Le nuage de points est construit à partir des coordonnées obtenues pour les deux premières composantes principales.

```
plot(  
  coordonnees_acp[, 1],  
  coordonnees_acp[, 2],  
  xlab = "PC1 - Taille du réseau (67,6 %)",  
  ylab = "PC2 - Ratio d'abonnés (20,6 %)",  
  main = "Bibliothèques selon les deux premières composantes",  
  pch = 20,  
)
```

Résultats

Le tableau obtenu présente, pour chaque bibliothèque, ses coordonnées sur les deux premières composantes principales (PC1 et PC2).

```
> head(tableau_coordonnees_acp)  
      Nom_bibliotheque      PC1      PC2  
1   Addington Highlands Twp -0.9548785  1.1027859  
2   Admaston/Bromley Twp -1.9201145 -1.0532224  
3           Ajax      2.0513166 -0.4432186  
4   Alderville FN -2.6129716  1.2636550  
5   Alfred & Plantagenet Twp  0.6754153 -0.2819567  
6 Algonquins of Pikwakanagan FN -2.9626971 -0.6415235
```

La figure 8 représente les bibliothèques selon les deux premières composantes principales.




Figure 8 : Bibliothèques selon les deux premières composantes principales

Analyse

La première composante distingue les bibliothèques selon la taille de leur réseau. Les établissements situés davantage vers la droite présentent des valeurs plus élevées de population desservie, d'heures d'ouverture, de nombre de succursales et de superficie.

La deuxième composante est associée au ratio abonnés/population. Les bibliothèques situées plus haut se distinguent par un ratio plus élevé.

L'ACP permet ainsi de représenter simultanément plusieurs caractéristiques des bibliothèques et de faire ressortir certains établissements dont le profil s'éloigne davantage de celui de l'ensemble.

7.5 Variance expliquée

Objectif

Examiner la proportion de variance expliquée par chacune des composantes principales.

Code

La variance expliquée est calculée à partir des écarts-types des composantes.

```
variance_expliquee <- acp$sdev^2 / sum(acp$sdev^2)
```

Les résultats sont regroupés dans un tableau.

```
tableau_variance_acp <- data.frame(  
  Composante = c("PC1", "PC2", "PC3", "PC4", "PC5"),  
  Variance_expliquee = round(variance_expliquee * 100, 2)  
)
```

Les résultats sont représentés graphiquement.

```
barplot(  
  variance_expliquee * 100,  
  names.arg = c("PC1", "PC2", "PC3", "PC4", "PC5"),  
  xlab = "Composantes principales",  
  ylab = "Variance expliquée (%)",  
  main = "Variance expliquée par les composantes"  
)
```

Résultats

Ce tableau présente la proportion de variance expliquée par chacune des cinq composantes.

```
tableau_variance_acp  
  
  Composante Variance_expliquee  
1         PC1             67.63  
2         PC2             20.57  
3         PC3              8.10  
4         PC4              1.98  
5         PC5              1.71
```

La figure 9 illustre la part de variance expliquée par chacune des cinq composantes.




Figure 9 : Variance expliquée par les composantes principales

Analyse

La première composante domine nettement l'analyse avec 67,63 % de la variance expliquée. L'ajout de la deuxième porte la proportion cumulée à 88,21 %. Les trois autres composantes apportent relativement peu d'information supplémentaire.

L'ACP permet ainsi de résumer les cinq caractéristiques étudiées en deux dimensions principales : la taille du réseau et le ratio d'abonnés.

SECTION 8 : SAUVEGARDE DES RÉSULTATS

Cette section permet d'enregistrer les principaux tableaux produits afin de les conserver et de les réutiliser dans les étapes suivantes du projet.

8.1 Préparation du dossier des résultats

Objectif

Créer le dossier destiné à recevoir les tableaux des résultats.

Code

Le dossier Resultats est créé s'il n'existe pas déjà.

```
dossier_resultats <- file.path(  
  "Resultats",  
  "Analyse statistiques, correlation, regression et ACP"  
)  
  
if (!dir.exists(dossier_resultats)) {  
  dir.create(dossier_resultats, recursive = TRUE)  
}
```

Résultats

Le dossier est créé automatiquement s'il n'existe pas déjà dans le projet.

Analyse

Les fichiers produits par les analyses sont regroupés dans un même dossier.

8.2 Sauvegarde des tableaux

Objectif

Enregistrer les tableaux produits par les analyses statistiques dans des fichiers CSV.

Code

Les sept tableaux à sauvegarder sont d'abord regroupés dans une liste.

```
tableaux_resultats <- list(  
  statistiques_descriptives,  
  tableau_correlations,  
  tableau_correlations_log,  
  tableau_regression,  
  tableau_variance_acp,  
  tableau_composantes_acp,  
  tableau_coordonnees_acp  
)
```

Les noms des fichiers CSV sont ensuite définis.

```
noms_fichiers <- c(  
  "Statistiques_descriptives.csv",  
  "Tableau_correlations_pearson.csv",  
  "Tableau_correlations_pearson_log.csv",  
  "Tableau_regression_multiple.csv",  
  "Variance_expliquee_ACP.csv",  
  "Composantes_ACP.csv",  
  "Coordonnees_bibliotheques_ACP.csv"  
)
```

Une boucle parcourt les tableaux et les enregistre dans le dossier des résultats.

```
for (i in 1:length(tableaux_resultats)) {  
  
  write.csv(  
    tableaux_resultats[[i]],  
    file.path(dossier_resultats, noms_fichiers[i]),  
    row.names = FALSE  
  )  
}
```

Résultats

Les sept tableaux sont enregistrés dans le dossier des résultats sous forme de fichiers CSV.

Analyse

Cette sauvegarde permet de conserver les principaux résultats des analyses dans des fichiers distincts.

8.3 Confirmation de la sauvegarde

Objectif

Confirmer que les tableaux ont été enregistrés dans le dossier prévu.

Code

Le chemin complet du dossier contenant les résultats est affiché.

```
cat(  
  "\nLes tableaux ont été enregistrés dans le dossier :",  
  file.path(getwd(), dossier_resultats),  
  "\n"  
)
```

Résultats

Un message confirme l'emplacement du dossier contenant les fichiers CSV enregistrés.

Analyse

Cette confirmation permet de vérifier que la sauvegarde a été effectuée et de repérer l'emplacement des fichiers.

CONCLUSION

Les analyses statistiques ont permis de mieux comprendre les caractéristiques des bibliothèques étudiées et les relations associées à leur offre technologique. Les statistiques descriptives et les visualisations ont d'abord montré une forte variabilité entre les bibliothèques ainsi que des distributions très asymétriques pour plusieurs variables.

Après transformation logarithmique, les corrélations ont fait ressortir plus clairement certaines relations avec l'indice de ressources technologiques. La régression multiple a ensuite montré qu'un modèle plus simple fondé sur la superficie et le ratio abonnés/population permettait de limiter les problèmes de multicolinéarité observés dans le modèle initial. Ce modèle n'explique toutefois qu'environ 14 % de la variation de l'indice et ses diagnostics montrent certaines limites, ce qui impose une interprétation prudente des résultats.

Enfin, l'ACP montre que les deux premières composantes expliquent 88,21 % de la variance des cinq caractéristiques étudiées. Elles représentent principalement la taille du réseau et le ratio abonnés/population. Cette représentation synthétique des bibliothèques a ensuite servi à approfondir l'analyse de leurs profils dans la phase de regroupement.

BIBLIOGRAPHIE

- Bicanic, S. (2023). *Ontario public library statistics 2021* [Data set]. Kaggle. <https://www.kaggle.com/datasets/sophiebicanic/ontario-public-library-statistics>
- Government of Ontario. (n.d.). *Ontario public library statistics* [Data set]. Ontario Data Catalogue. <https://data.ontario.ca/en/dataset/ontario-public-library-statistics>
- Government of Ontario. (n.d.). *Open Government Licence – Ontario*. <https://www.ontario.ca/page/open-government-licence-ontario>

ANNEXE

Vérifications de l'importation du jeu de données

A1 - Structure du jeu de données

```
> str(donnees)
'data.frame': 295 obs. of 32 variables:
 $ Nom_bibliotheque      : chr "Addington Highlands Twp" "Admaston/Bromley Twp" "Ajax" "Alderville FN" ...
 $ Nom_responsable       : chr "Bonnie Leoen" "Jane Wouda" "Sarah Vaisler" "Shannon Catherwood" ...
 $ Population_residente  : int 1712 2935 127400 313 9680 453 5691 1166 8795 3440 ...
 $ Population_contractuelle : int 0 0 0 0 0 0 0 795 7178 0 ...
 $ Nb_abonnes_actifs     : int 925 342 23302 190 1743 65 924 159 4968 636 ...
 $ Nb_menages_servis    : int 2762 1408 38400 NA 4218 NA 3434 841 7466 1857 ...
 $ Nb_points_service     : int 2 1 3 1 5 1 3 1 1 2 ...
 $ Nb_succursales       : int 2 1 3 1 5 1 3 1 1 2 ...
 $ Heures_ouverture     : num 30 12 152 20 85 ...
 $ Nb_imprimantes_3D    : int 0 0 2 0 0 0 0 0 0 1 ...
 $ Nb_espaces_creation  : int 0 0 0 0 0 0 0 1 0 1 ...
 $ Nb_locations_salles  : int 0 0 0 0 0 0 0 0 34 17 ...
 $ Nb_bibliotheques_ephemeres : int 0 0 0 0 0 0 0 0 4 0 ...
 $ Superficie           : int 3534 1394 48000 500 5595 118 16712 2322 13500 3822 ...
 $ Nb_postes_publics    : int 12 4 62 3 11 6 7 6 11 3 ...
 $ Nb_postes_OPAC       : int 12 4 11 0 0 0 4 1 3 3 ...
 $ Nb_postes_internet   : int 12 4 51 3 11 6 4 6 4 3 ...
 $ Nb_appareils_pretes  : int 4 8 0 3 0 1 3 3 4 2 ...
 $ Nb_liseuses          : int 2 1 0 2 0 0 0 2 0 0 ...
 $ Population_desservie  : int 1712 2935 127400 313 9680 453 5691 1961 15973 3440 ...
 $ Ratio_abonnes_population : num 0.54 0.117 0.183 0.607 0.18 ...
 $ Imprimantes_3D_1000  : num 0 0 0.0157 0 0 ...
 $ Espaces_creation_1000 : num 0 0 0 0 ...
 $ Postes_internet_1000 : num 7.01 1.36 0.4 9.58 1.14 ...
 $ Appareils_pretes_1000 : num 2.34 2.73 0 9.58 0 ...
 $ Liseuses_1000        : num 1.168 0.341 0 6.39 0 ...
 $ Z_Imprimantes_3D     : num -0.237 -0.237 -0.156 -0.237 -0.237 ...
 $ Z_Espaces_creation   : num -0.119 -0.119 -0.119 -0.119 -0.119 ...
 $ Z_Postes_internet    : num 0.266 -0.237 -0.323 0.496 -0.258 ...
 $ Z_Appareils_pretes   : num 0.0553 0.1256 -0.3664 1.3637 -0.3664 ...
 $ Z_Liseuses           : num 0.0792 -0.1458 -0.2384 1.4985 -0.2384 ...
 $ Indice_ressources_technologiques : num 0.00895 -0.12274 -0.24072 0.60045 -0.24371 ...
```

A2 - Premières observations du jeu de données

```
> head(donnees)
  Nom_bibliotheque Nom_responsable Population_residente Population_contractuelle Nb_abonnes_actifs Nb_menages_servis
1 Addington Highlands Twp Bonnie Leoen 1712 0 925 2762
2 Admaston/Bromley Twp Jane Wouda 2935 0 342 1408
3 Ajax Sarah Vaisler 127400 0 23302 38400
4 Alderville FN Shannon Catherwood 313 0 190 NA
5 Alfred & Plantagenet Twp Dominique Lacelle 9680 0 1743 4218
6 Algonquins of Pikwakanagan FN Estelle Amikons 453 0 65 NA
  Nb_points_service Nb_succursales Heures_ouverture Nb_imprimantes_3D Nb_espaces_creation Nb_locations_salles Nb_bibliotheques_ephemeres
1 2 2 30.0 0 0 0 0
2 1 1 12.0 0 0 0 0
3 3 3 151.5 2 0 0 0
4 1 1 20.0 0 0 0 0
5 5 5 85.0 0 0 0 0
6 1 1 20.0 0 0 0 0
  Superficie Nb_postes_publics Nb_postes_OPAC Nb_postes_internet Nb_appareils_pretes Nb_liseuses Population_desservie Ratio_abonnes_population
1 3534 12 12 12 4 2 1712 0.5403037
2 1394 4 4 4 8 1 2935 0.1165247
3 48000 62 11 51 0 0 127400 0.1829042
4 500 3 0 3 3 2 313 0.6070288
5 5595 11 0 11 0 0 9680 0.1800620
6 118 6 0 6 1 0 453 0.1434879
  Imprimantes_3D_1000 Espaces_creation_1000 Postes_internet_1000 Appareils_pretes_1000 Liseuses_1000 Z_Imprimantes_3D Z_Espaces_creation
1 0.00000000 0 7.009346 2.336449 1.1682243 -0.2367852 -0.1193505
2 0.00000000 0 1.362862 2.725724 0.3407155 -0.2367852 -0.1193505
3 0.01569859 0 0.400314 0.0000000 0.0000000 -0.1561679 -0.1193505
4 0.00000000 0 9.584665 9.584665 6.3897764 -0.2367852 -0.1193505
5 0.00000000 0 1.136364 0.0000000 0.0000000 -0.2367852 -0.1193505
6 0.00000000 0 13.245033 2.207506 0.0000000 -0.2367852 -0.1193505
  Z_Postes_internet Z_Appareils_pretes Z_Liseuses Indice_ressources_technologiques
1 0.2663635 0.0534007 0.07917182 0.00894793
2 -0.2374011 0.12560895 -0.14576896 -0.12273936
3 -0.3232771 -0.36641695 -0.23838528 -0.24071955
4 0.4961267 1.36373005 1.49854044 0.60045229
5 -0.2576087 -0.36641695 -0.23838528 -0.24370932
6 0.8226952 0.03206429 -0.23838528 0.05204771
```