

Table des matières

Introduction	3
Section 1 : Importation des données	4
Section 2 : Préparation des données	5
2.1 Sélection des variables	5
2.2 Vérification des valeurs manquantes	6
2.3 Sélection des observations complètes	8
Section 3 : Transformation et standardisation des variables	9
3.1 Distribution des variables	9
3.2 Transformation logarithmique	11
3.3 Distribution après transformation	11
3.4 Standardisation des variables	13
Section 4 : Détermination du nombre de groupes	14
4.1 Méthode du coude	14
4.2 Indice de silhouette	16
4.3 Comparaison des solutions	19
4.4 Choix de la solution finale	21

Section 5 : Représentation des groupes avec l'ACP.....	22
5.1 Réalisation de l'ACP	22
5.2 Représentation des groupes	24
Section 6 : Description et visualisation des groupes	26
6.1 Création du tableau des résultats.....	26
6.2 Profil standardisé des groupes	27
6.3 Nuages de points	29
Section 7 : Synthèse et sauvegarde des résultats	32
7.1 Attribution d'un nom aux profils	32
7.2 Création du tableau synthèse des profils	33
7.3 Création des profils standardisés	35
7.4 Création du dossier de résultats.....	37
7.5 Sauvegarde des résultats.....	37
Conclusion.....	39
Bibliographie	40
Annexe.....	41

INTRODUCTION

Ce rapport présente l'analyse de regroupement réalisée dans le cadre du projet sur l'offre technologique et les profils des bibliothèques publiques de l'Ontario. Les analyses reposent sur les statistiques 2021 des bibliothèques publiques de l'Ontario, obtenues à partir du jeu de données publié par Sophie Bicanic sur Kaggle et provenant des données du gouvernement de l'Ontario. Le jeu de données a préalablement été préparé et enrichi afin de produire les variables et les indicateurs nécessaires à l'analyse.

L'objectif est de déterminer s'il est possible d'identifier différents profils de bibliothèques à partir de six caractéristiques : la population desservie, le nombre de succursales, les heures d'ouverture, la superficie, le ratio abonnés/population et l'indice de ressources technologiques.

Les données sont d'abord sélectionnées, transformées et standardisées afin de permettre leur comparaison. La méthode K-means est ensuite utilisée pour former les groupes. Le nombre de groupes est déterminé à partir de la méthode du coude, de l'indice de silhouette et de l'interprétation des solutions obtenues. Une analyse en composantes principales (ACP) permet ensuite de représenter les groupes dans un espace à deux dimensions. Les profils retenus sont finalement décrits et comparés afin d'en dégager les principales caractéristiques.

SECTION 1 : IMPORTATION DES DONNÉES

Objectif

Importer le jeu de données préparé qui sera utilisé pour l'analyse de regroupement.

Code

Le chemin du fichier est d'abord défini et son existence est vérifiée.

```
fichier <- file.path(
  "Donnees",
  "Donnees preparees",
  "Bibliotheques_preparees.csv"
)

if (!file.exists(fichier)) {
  stop("Le fichier de données est introuvable : ", fichier)
}
```

Le jeu de données est ensuite importé dans R.

```
donnees <- read.csv(fichier, stringsAsFactors = FALSE)
```

Résultats

Le jeu de données a été importé correctement. Il contient 295 observations et 33 variables.

```
dim(donnees)
[1] 295 33
```

Analyse

Les 295 observations correspondent aux bibliothèques conservées à la suite de la préparation et de l'enrichissement des données. Le jeu de données peut maintenant être vérifié afin de s'assurer que sa structure et les variables nécessaires au clustering sont adéquates avant de commencer l'analyse.

SECTION 2 : PRÉPARATION DES DONNÉES

Avant de réaliser le clustering, les données doivent être préparées afin que seules les informations nécessaires à l'analyse soient utilisées. Cette section consiste à sélectionner les six variables de regroupement, à vérifier la présence de valeurs manquantes et à conserver les bibliothèques pour lesquelles ces variables sont complètes.

2.1 Sélection des variables

Objectif

Retenir les six variables qui seront utilisées pour regrouper les bibliothèques selon leurs principales caractéristiques.

Code

Les six variables prévues pour le clustering sont d'abord définies dans un vecteur.

```
variables_clustering <- c(
  "Population_desservie",
  "Nb_succursales",
  "Heures_ouverture",
  "Superficie",
  "Ratio_abonnes_population",
  "Indice_ressources_technologiques"
)
```

Elles sont ensuite sélectionnées dans le jeu de données afin de créer un nouveau tableau contenant uniquement les variables nécessaires à l'analyse.

```
donnees_clustering <- donnees[, variables_clustering]
```

Résultats

Le tableau créé contient 295 observations et 6 variables.

```
dim(donnees_clustering)
[1] 295  6
```

Analyse

Les variables retenues décrivent différentes caractéristiques des bibliothèques. Elles permettront ainsi de rechercher des regroupements de bibliothèques présentant des caractéristiques similaires.

Les 295 bibliothèques sont toujours présentes à cette étape. Seules les variables qui ne sont pas utilisées pour le clustering ont été retirées du nouveau tableau.

2.2 Vérification des valeurs manquantes

Objectif

Vérifier la présence de valeurs manquantes dans les six variables retenues afin de déterminer quelles observations pourront être utilisées pour le clustering.

Code

Le nombre de valeurs manquantes est d'abord calculé pour chaque variable.

```
colSums(is.na(donnees_clustering))
```

Les observations complètes sont ensuite identifiées.

```
observations_completes <- complete.cases(donnees_clustering)
```

Enfin, les bibliothèques comportant une valeur manquante sont affichées afin d'identifier les observations concernées.

```
donnees[
  !observations_completes,
  c(
    "Nom_bibliotheque",
    "Superficie",
    "Indice_ressources_technologiques"
  )
]
```

Résultats

La superficie contient 37 valeurs manquantes et l'indice de ressources technologiques en contient une. Les quatre autres variables sont complètes.

Population_desservie	Nb_succursales
0	0
Heures_ouverture	Superficie
0	37
Ratio_abonnes_population	Indice_ressources_tecnologiques
0	1

La liste complète des 38 bibliothèques concernées est présentée en annexe.

Analyse

Le clustering nécessite une valeur pour chacune des six variables utilisées. Les 38 observations incomplètes ne peuvent donc pas être utilisées directement dans l'analyse.

Une estimation des superficies manquantes à partir des autres variables a été envisagée. Les relations entre la superficie et les variables susceptibles de permettre cette estimation ont été examinées, mais les corrélations observées n'étaient pas suffisamment fortes pour justifier une estimation fiable. Il a donc été choisi de ne pas remplacer les valeurs manquantes par des valeurs estimées.

Les 257 observations complètes sont ainsi conservées pour la suite de l'analyse. Cette approche évite d'introduire dans le clustering des superficies artificielles qui pourraient influencer la formation des groupes.

2.3 Sélection des observations complètes

Objectif

Conserver uniquement les bibliothèques qui possèdent une valeur pour chacune des six variables de regroupement.

Code

Les observations identifiées comme complètes à l'étape précédente sont conservées dans le tableau utilisé pour le clustering.

```
donnees_clustering <- donnees_clustering[observations_completes,]
```

Les noms des bibliothèques correspondantes sont également conservés afin de pouvoir les associer aux groupes obtenus.

```
noms_bibliotheques <- donnees$Nom_bibliotheque[observations_completes]
```

Résultats

Après le retrait des 38 bibliothèques, le tableau contient 257 observations et 6 variables.

```
dim(donnees_clustering)
[1] 257  6
```

Analyse

Le jeu de données utilisé pour le clustering comprend maintenant 257 bibliothèques pour lesquelles les six variables retenues sont complètes.

Cette sélection permet de poursuivre l'analyse avec les mêmes six caractéristiques disponibles pour chacune des bibliothèques comparées.

SECTION 3 : TRANSFORMATION ET STANDARDISATION DES VARIABLES

Avant de réaliser le clustering, les variables doivent être préparées afin de limiter l'influence de leurs différences de distribution et d'échelle. Cette section examine d'abord leur distribution, applique une transformation logarithmique aux quatre premières variables, puis standardise l'ensemble des variables utilisées pour le clustering.

3.1 Distribution des variables

Objectif

Visualiser la distribution des six variables utilisées pour le clustering afin d'observer leur forme générale et de repérer les variables fortement asymétriques.

Code

Des libellés plus courts sont d'abord définis pour les graphiques.

```
libelles_variables <- c(
  "Population desservie",
  "Nombre de succursales",
  "Heures d'ouverture",
  "Superficie",
  "Ratio abonnés/population",
  "Indice technologique"
)
```

Une boucle permet finalement de créer un histogramme pour chacune des six variables sélectionnées.

```
for (i in 1:length(variables_clustering)) {
  hist(
    donnees_clustering[, variables_clustering[i]],
    main = libelles_variables[i],
    xlab = libelles_variables[i]
  )
}
```

Résultats

La figure 1 présente les histogrammes des six variables utilisées pour le clustering.




Figure 1 : Distribution des variables utilisées pour le clustering avant transformation

Analyse

Les distributions présentent une asymétrie vers la droite, particulièrement marquée pour les quatre premières variables. Ces valeurs peuvent exercer une influence importante sur les distances utilisées par le K-means.

Une transformation logarithmique sera appliquée aux quatre premières variables afin de réduire les écarts entre les valeurs élevées et les autres observations. Le ratio abonnés/population et l'indice technologique ne seront pas transformés. Leur distribution ne justifie pas ici la même transformation que celle appliquée aux quatre variables fortement asymétriques.

3.2 Transformation logarithmique

Objectif

Réduire l'influence des valeurs très élevées dans les quatre premières variables avant le clustering.

Code

Une copie des données est d'abord créée afin de conserver les valeurs originales.

```
donnees_clustering_transformees <- donnees_clustering
```

Une boucle applique ensuite une transformation logarithmique aux quatre premières variables.

```
for (i in 1:4) {  
  donnees_clustering_transformees[, variables_clustering[i]] <-  
    log10(donnees_clustering_transformees[, variables_clustering[i]])  
}
```

Résultats

Les quatre premières variables sont transformées avec le logarithme en base 10. Les deux autres variables demeurent inchangées.

Analyse

La transformation logarithmique réduit les écarts entre les valeurs les plus élevées et les autres observations. Il faut maintenant examiner les distributions obtenues afin de vérifier l'effet de cette transformation.

3.3 Distribution après transformation

Objectif

Vérifier l'effet de la transformation logarithmique sur la distribution des quatre variables transformées.

Code

Une nouvelle fenêtre graphique est divisée en quatre espaces.

```
dev.new()  
  
par(mfrow = c(2, 2))
```

Une boucle permet ensuite de créer un histogramme pour chacune des quatre variables après transformation.

```
for (i in 1:4) {  
  hist(  
    donnees_clustering_transformees[, variables_clustering[i]],  
    main = libelles_variables[i],  
    xlab = "Valeurs après transformation log10"  
  )  
}
```

Résultats

La figure 2 présente la distribution des quatre variables après transformation logarithmique.




Figure 2 : Distribution des variables après transformation logarithmique

Analyse

La transformation réduit fortement l'étendue des valeurs et l'asymétrie observée. La population desservie et la superficie présentent maintenant une distribution beaucoup plus équilibrée. Le nombre de succursales et les heures d'ouverture demeurent asymétriques, mais les valeurs élevées sont moins éloignées du reste des observations.

La transformation permet ainsi de réduire l'influence des valeurs très élevées avant le calcul des distances utilisées pour le clustering.

3.4 Standardisation des variables

Objectif

Standardiser les six variables afin qu'elles soient comparables avant le clustering.

Code

La fonction `scale()` standardise les six variables transformées.

```
donnees_clustering_standardisees <- scale(donnees_clustering_transformees)
```

Résultats

Les six variables sont maintenant exprimées sur une même échelle standardisée.

Analyse

Les variables utilisées n'ont pas les mêmes unités ni les mêmes échelles. Sans standardisation, celles dont les valeurs varient davantage pourraient avoir plus d'influence sur les distances calculées par le K-means. La standardisation permet ainsi à chaque variable de contribuer de façon comparable au clustering.

SECTION 4 : DÉTERMINATION DU NOMBRE DE GROUPES

Cette section vise à déterminer le nombre de groupes à retenir pour le clustering. La méthode du coude est d'abord utilisée pour identifier les solutions possibles. Celles-ci sont ensuite comparées à l'aide de l'indice de silhouette et de leurs caractéristiques afin de choisir la solution finale.

4.1 Méthode du coude

Objectif

Observer la variation de l'inertie intra-groupes pour différents nombres de groupes afin d'identifier les solutions à examiner.

Code

Un vecteur est d'abord créé pour conserver les valeurs d'inertie, puis une liste permet de conserver les résultats des différents clusterings.

```
inertie <- numeric(10)
clusterings <- list()
```

La sélection aléatoire est fixée afin de rendre les résultats reproductibles.

```
set.seed(20)
```

Une boucle permet ensuite de tester de 1 à 10 groupes. Pour chaque nombre de groupes, le K-means est effectué avec 20 essais utilisant des centres de départ différents. Le résultat du clustering et son inertie sont conservés.

```
for (k in 1:10) {
  clusterings[[k]] <- kmeans(
    donnees_clustering_standardisees,
    centers = k,
    nstart = 20
  )
  inertie[k] <- sum(clusterings[[k]]$withinss)
}
```

Les valeurs d'inertie sont affichées, puis représentées graphiquement. Les points sont reliés afin de mieux visualiser l'évolution de l'inertie.

```
plot(  
  inertie,  
  type = "b",  
  main = "Méthode du coude",  
  xlab = "Nombre de groupes",  
  ylab = "Inertie intra-groupes"  
)
```

Résultats

L'inertie diminue de 1536 avec un seul groupe à 253,26 avec dix groupes.

```
inertie  
[1] 1536.0000  958.1785  696.3040  545.1122  417.3700  365.5813  324.2663  
[8]  294.0153  271.9462  253.2605
```

La figure 3 présente cette évolution pour les solutions de 1 à 10 groupes.




Figure 3 : Détermination du nombre de groupes par la méthode du coude

Analyse

La diminution de l'inertie est importante pour les premières solutions, puis devient progressivement moins marquée. Comme aucun coude unique ne se dégage clairement, les solutions de deux à cinq groupes seront comparées à l'aide de l'indice de silhouette.

4.2 Indice de silhouette

Objectif

Comparer les solutions à deux, trois, quatre et cinq groupes suggérées par la méthode du coude afin de déterminer laquelle offre le meilleur regroupement.

Code

Les distances entre les bibliothèques sont calculées à partir des données standardisées.

```
distances <- dist(donnees_clustering_standardisees)
```

Un vecteur est créé pour conserver les silhouettes moyennes.

```
silhouettes_moyennes <- numeric(4)
```

Une boucle calcule ensuite la silhouette des solutions de deux à cinq groupes, conserve leur largeur moyenne et produit les graphiques correspondants.

```
for (k in 2:5) {  
  s <- silhouette(  
    clusterings[[k]]$cluster,  
    distances  
  )  
  
  silhouettes_moyennes[k - 1] <- mean(s[, "sil_width"])  
  
  plot(  
    s,  
    main = paste("Silhouette -", k, "groupes")  
  )  
}
```

Les résultats sont finalement regroupés dans un tableau.

```
tableau_silhouettes <- data.frame(  
  Nb_groupes = 2:5,  
  Silhouette_moyenne = silhouettes_moyennes  
)  
  
tableau_silhouettes$Silhouette_moyenne <-  
  round(tableau_silhouettes$Silhouette_moyenne, 3)
```

Résultats

Les figures 4 à 7 présentent les silhouettes des quatre solutions comparées.




Figure 4 : Silhouette de la solution à deux groupes




Figure 5 : Silhouette de la solution à trois groupes




Figure 6 : Silhouette de la solution à quatre groupes




Figure 7 : Silhouette de la solution à cinq groupes

Le tableau_silhouettes présente leur largeur moyenne de silhouette.

tableau_silhouettes		
	Nb_groupes	Silhouette_moyenne
1	2	0.415
2	3	0.445
3	4	0.312
4	5	0.343

Analyse

La solution à trois groupes présente la largeur moyenne de silhouette la plus élevée (0,445), suivie par la solution à deux groupes (0,415). Les solutions à quatre et cinq groupes obtiennent des valeurs plus faibles, soit respectivement 0,312 et 0,343.

La solution à trois groupes offre la meilleure séparation parmi les solutions comparées, bien que la valeur obtenue indique que la structure des groupes demeure modérée. Les solutions à deux et trois groupes seront examinées plus précisément à l'étape suivante.

4.3 Comparaison des solutions

Objectif

Comparer la taille et les centres des groupes pour les solutions à deux et trois groupes.

Code

Pour chacune des deux solutions, le nombre de bibliothèques par groupe est affiché avec `table()`.

```
table(clusterings[[2]]$cluster)
table(clusterings[[3]]$cluster)
```

Les centres des groupes sont ensuite affichés et arrondis à deux décimales.

```
round(clusterings[[2]]$centers, 2)
round(clusterings[[3]]$centers, 2)
```

Résultats

La solution à deux groupes répartit les 257 bibliothèques en groupes de 197 et 60 bibliothèques.

```
 1    2
197  60
```

La solution à trois groupes forme des groupes de 58, 180 et 19 bibliothèques.

```
 1    2    3
58 180  19
```

Les centres standardisés de la solution à deux groupes sont :

	Population_desservie	Nb_succursales	Heures_ouverture	Superficie
1	-0.38	-0.43	-0.43	-0.39
2	1.25	1.41	1.43	1.29
	Ratio_abonnes_population	Indice_ressources_technologiques		
1	0.05		0.09	
2	-0.16		-0.29	

Les centres standardisés de la solution à trois groupes sont :

	Population_desservie	Nb_succursales	Heures_ouverture	Superficie
1	1.28	1.45	1.46	1.31
2	-0.24	-0.42	-0.38	-0.30
3	-1.62	-0.49	-0.83	-1.14
	Ratio_abonnes_population	Indice_ressources_technologiques		
1	-0.15		-0.29	
2	-0.21		-0.14	
3	2.45		2.18	

Analyse

La solution à deux groupes distingue les grandes bibliothèques, qui présentent des valeurs élevées pour la population, le nombre de succursales, les heures d'ouverture et la superficie, des bibliothèques plus petites présentant des valeurs inférieures à la moyenne pour ces caractéristiques.

La solution à trois groupes conserve cette distinction, mais fait apparaître un troisième groupe de 19 bibliothèques. Celui-ci se caractérise par une population et une superficie inférieures à la moyenne, mais par un ratio abonnés/population (2,45) et un indice technologique (2,18) particulièrement élevés.

Cette solution permet donc de distinguer un profil qui n'apparaît pas dans la solution à deux groupes. La silhouette moyenne de ce petit groupe étant toutefois faible, son interprétation doit demeurer prudente.

4.4 Choix de la solution finale

Objectif

Retenir la solution à trois groupes à partir des résultats obtenus avec la méthode du coude, l'indice de silhouette et la comparaison des groupes.

Code

La solution à trois groupes, déjà calculée et conservée dans la liste `clusterings`, est enregistrée comme solution finale.

```
clustering_final <- clusterings[[3]]
```

Résultats

La solution à trois groupes est retenue pour la suite de l'analyse.

Analyse

La solution à trois groupes présente la largeur moyenne de silhouette la plus élevée parmi les solutions comparées (0,445) et permet de distinguer un profil supplémentaire caractérisé par un ratio d'abonnés et un indice technologique élevés.

Cette valeur indique toutefois une structure de regroupement modérée plutôt qu'une séparation très nette des observations. La solution à trois groupes est donc retenue comme représentation exploratoire des principaux profils présents dans les données.

SECTION 5 : REPRÉSENTATION DES GROUPES AVEC L'ACP

Une analyse en composantes principales (ACP) est réalisée afin de représenter les groupes obtenus avec le K-means dans un espace à deux dimensions.

5.1 Réalisation de l'ACP

Objectif

Réaliser une ACP à partir des mêmes variables standardisées que celles utilisées pour le K-means.

Code

L'ACP est réalisée avec la fonction `prcomp()`. Comme les données ont déjà été standardisées avant le clustering, elles ne sont ni centrées ni standardisées de nouveau.

```
acp_clustering <- prcomp(  
  donnees_clustering_standardisees,  
  center = FALSE,  
  scale. = FALSE  
)
```

Résultats

Le premier tableau présente la variance expliquée par chacune des six composantes principales.

Importance of components:	PC1	PC2	PC3	PC4	PC5	PC6
Standard deviation	1.8918	1.1000	0.8310	0.59115	0.31507	0.26810
Proportion of Variance	0.5965	0.2017	0.1151	0.05824	0.01654	0.01198
Cumulative Proportion	0.5965	0.7981	0.9132	0.97148	0.98802	1.00000

Le deuxième tableau présente les coefficients des six variables pour chacune des composantes principales.

	PC1	PC2	PC3	PC4	PC5	
PC6						
Population_desservie	0.498	0.102	0.054	-0.392	0.158	-
0.748						
Nb_succursales	0.441	-0.284	-0.152	0.698	-0.414	-
0.209						
Heures_ouverture	0.490	-0.237	-0.082	0.124	0.734	
0.378						
Superficie	0.488	-0.105	0.007	-0.513	-0.515	
0.472						
Ratio_abonnes_population	-0.141	-0.708	0.680	-0.077	0.005	-
0.099						
Indice_ressources_technologiques	-0.244	-0.583	-0.710	-0.273	0.016	-
0.146						

Analyse

La première composante principale (PC1) explique 59,6 % de la variance, tandis que la deuxième (PC2) en explique 20,2 %. Ensemble, elles représentent 79,8 % de la variance totale et résument une grande partie de l'information contenue dans les six variables.

PC1 est associée à la population desservie, au nombre de succursales, aux heures d'ouverture et à la superficie. Elle représente la taille du réseau.

PC2 est associée au ratio abonnés/population et à l'indice des ressources technologiques. Son signe sera inversé dans la représentation graphique afin que les valeurs élevées sur cette dimension apparaissent dans le sens positif de l'axe.

5.2 Représentation des groupes

Objectif

Représenter les bibliothèques selon les deux premières composantes principales et leur groupe K-means.

Code

Les coordonnées des bibliothèques sont extraites. Le signe de la deuxième composante est inversé pour faciliter son interprétation.

```
coordonnees_acp <- acp_clustering$x  
coordonnees_acp[, 2] <- -coordonnees_acp[, 2]
```

Les bibliothèques sont ensuite représentées avec une couleur correspondant à leur groupe K-means.

```
noms_groupes <- c("Groupe 1", "Groupe 2", "Groupe 3")  
couleurs_groupes <- c("#8064A2", "#ED7D31", "#70AD47")  
  
plot(  
  coordonnees_acp[, 1],  
  coordonnees_acp[, 2],  
  col = couleurs_groupes[clustering_final$cluster],  
  pch = 20,  
  xlab = "PC1 - Taille du réseau (59,6 %)",  
  ylab = "PC2 - Abonnés et technologie (20,2 %)",  
  main = "Groupes de bibliothèques - ACP"  
)  
  
legend(  
  "topright",  
  legend = noms_groupes,  
  col = couleurs_groupes,  
  pch = 20  
)
```

Résultats

La figure 8 présente les 257 bibliothèques selon les deux premières composantes principales et leur groupe K-means.




Figure 8 : Représentation des groupes de bibliothèques selon les deux premières composantes principales

Analyse

La représentation permet de visualiser les trois profils obtenus avec le K-means. Le groupe 1 se distingue par la taille du réseau, le groupe 3 par les abonnés et les ressources technologiques, tandis que le groupe 2 occupe une position plus centrale.

SECTION 6 : DESCRIPTION ET VISUALISATION DES GROUPES

Cette section vise à décrire les trois groupes retenus et à faire ressortir leurs principales caractéristiques. Les profils sont comparés à partir des variables utilisées pour le clustering, puis représentés graphiquement afin de faciliter leur interprétation.

6.1 Création du tableau des résultats

Objectif

Associer chaque bibliothèque au groupe obtenu par le K-means et combiner cette information avec les valeurs originales des six variables utilisées pour le clustering.

Code

Un nouveau tableau est créé à partir du nom des bibliothèques, du groupe attribué par le K-means et des données originales utilisées pour le clustering.

```
resultats_clustering <- data.frame(  
  Nom_bibliotheque = noms_bibliotheques,  
  Groupe = clustering_final$cluster,  
  donnees_clustering  
)
```

Résultats

Les premières observations montrent que chaque bibliothèque est associée à son groupe ainsi qu'aux valeurs originales des six variables utilisées pour le clustering.

```
head(resultats_clustering)
```

	Nom_bibliotheque	Groupe	Population_desservie	Nb_succursales
1	Addington Highlands Twp	2	1712	2
2	Admaston/Bromley Twp	2	2935	1
3	Ajax	1	127400	3
4	Alderville FN	3	313	1
5	Alfred & Plantagenet Twp	2	9680	5
6	Algonquins of Pikwakanagan FN	2	453	1

	Heures_ouverture	Superficie	Ratio_abonnes_population
1	30.0	3534	0.5403037
2	12.0	1394	0.1165247
3	151.5	48000	0.1829042
4	20.0	500	0.6070288
5	85.0	5595	0.1800620
6	20.0	118	0.1434879

```
Indice_ressources_technologiques
1          0.00894793
2        -0.12273936
3        -0.24071955
4         0.60045229
5        -0.24370932
6         0.05204771
```

Analyse

Ce tableau permet d'associer les groupes obtenus aux valeurs originales des variables afin d'en décrire les caractéristiques.

6.2 Profil standardisé des groupes

Objectif

Comparer les centres des trois groupes sur les six variables standardisées utilisées dans le clustering.

Code

Une nouvelle fenêtre graphique est ouverte. Les marges inférieure et droite sont agrandies afin de laisser suffisamment d'espace pour les noms des variables et pour placer la légende à droite du graphique.

```
dev.new()
par(mar = c(9, 4, 4, 9))
```

Un diagramme en barres permet ensuite de comparer les centres des trois groupes pour chacune des six variables.

```
barplot(
  clustering_final$centers,
  beside = TRUE,
  names.arg = libelles_variables,
  col = couleurs_groupes,
  main = "Profil standardisé des groupes",
  ylab = "Score Z",
)
```

Une ligne pointillée est ajoutée à zéro pour représenter la moyenne générale.

```
abline(h = 0, lty = 2)
```

Une légende est ensuite ajoutée pour identifier les trois groupes.

```
legend(  
  "topright",  
  inset = c(-0.3, 0),  
  xpd = TRUE,  
  legend = noms_groupes,  
  fill = couleurs_groupes  
)
```

Résultats

La figure 9 présente les centres standardisés des trois groupes pour les six variables utilisées dans le clustering.




Figure 9 : Profil standardisé des trois groupes selon les variables utilisées pour le clustering

Analyse

Le groupe 1 présente des valeurs supérieures à la moyenne pour la population desservie, le nombre de succursales, les heures d'ouverture et la superficie. Son ratio abonnés/population et son indice technologique sont légèrement inférieurs à la moyenne.

Le groupe 2 présente des valeurs légèrement inférieures à la moyenne pour l'ensemble des variables et correspond à un profil intermédiaire.

Le groupe 3 se distingue par des valeurs très faibles pour la taille du réseau, mais très élevées pour le ratio abonnés/population et l'indice technologique. Il représente donc un petit groupe de bibliothèques de faible envergure ayant une forte intensité relative d'abonnement et de ressources technologiques.

6.3 Nuages de points

Objectif

Visualiser les groupes selon deux combinaisons de variables qui font ressortir leurs principales différences.

Code

Un premier nuage de points représente la population desservie et l'indice technologique. Une échelle logarithmique est utilisée pour la population afin de tenir compte des grandes différences de taille entre les bibliothèques.

```
plot(
  resultats_clustering$Population_desservie,
  resultats_clustering$Indice_ressources_technologiques,
  log = "x",
  pch = 20,
  col = couleurs_groupes[resultats_clustering$Groupe],
  main = "Population et indice technologique",
  xlab = "Population desservie",
  ylab = "Indice technologique"
)

legend(
  "topright",
  legend = noms_groupes,
  col = couleurs_groupes,
  pch = 20
)
```

Un deuxième nuage de points représente le ratio abonnés/population et l'indice technologique.

```
plot(
  resultats_clustering$Ratio_abonnes_population,
  resultats_clustering$Indice_ressources_technologiques,
  pch = 20,
  col = couleurs_groupes[resultats_clustering$Groupe],
  main = "Utilisation et offre technologique",
  xlab = "Ratio abonnés/population",
  ylab = "Indice technologique"
)

legend(
  "topright",
  legend = noms_groupes,
  col = couleurs_groupes,
  pch = 20
)
```

Résultats

La figure 10 présente les groupes selon la population desservie et l'indice technologique.




Figure 10 : Répartition des groupes selon la population desservie et l'indice technologique

La figure 11 présente leur répartition selon le ratio abonnés/population et l'indice technologique.




Figure 11 : Répartition des groupes selon le ratio abonnés/population et l'indice technologique

Analyse

La figure 10 montre que le groupe 1 rassemble les bibliothèques desservant les populations les plus importantes. Le groupe 2 occupe surtout une position intermédiaire, tandis que le groupe 3 regroupe de petites bibliothèques avec des indices technologiques élevés.

La figure 11 distingue clairement le groupe 3, qui comprend les valeurs les plus élevées du ratio abonnés/population et de l'indice technologique. Les groupes 1 et 2 sont davantage concentrés dans les valeurs faibles ou intermédiaires de ces deux variables.

SECTION 7 : SYNTHÈSE ET SAUVEGARDE DES RÉSULTATS

Cette dernière section vise à synthétiser les profils obtenus à partir du clustering et à conserver les principaux résultats de l'analyse. Un nom descriptif est attribué à chaque profil, leurs caractéristiques sont résumées à l'aide des valeurs médianes, puis les résultats sont enregistrés dans des fichiers distincts.

7.1 Attribution d'un nom aux profils

Objectif

Attribuer un nom descriptif à chacun des trois groupes afin de résumer leurs principales caractéristiques.

Code

À partir des caractéristiques observées dans la section précédente, un nom est attribué à chacun des trois profils.

```
noms_profils <- c(
  "Grands réseaux de bibliothèques",
  "Bibliothèques locales intermédiaires",
  "Petites bibliothèques à forte offre technologique"
)
```

Le nom du profil correspondant au groupe de chaque bibliothèque est ensuite ajouté au tableau des résultats.

```
resultats_clustering$Profil <- noms_profils[resultats_clustering$Groupe]
```

Résultats

Chaque bibliothèque est maintenant associée à son numéro de groupe et à un nom de profil correspondant.

```
head(resultats_clustering[, c("Nom_bibliotheque", "Groupe",
"Profil")])
```

	Nom_bibliotheque	Groupe	
1	Addington Highlands Twp	2	
2	Admaston/Bromley Twp	2	
3	Ajax	1	
4	Alderville FN	3	
5	Alfred & Plantagenet Twp	2	
6	Algonquins of Pikwakanagan FN	2	

	Profil
1	Bibliothèques locales intermédiaires
2	Bibliothèques locales intermédiaires
3	Grands réseaux de bibliothèques
4	Petites bibliothèques à forte offre technologique
5	Bibliothèques locales intermédiaires
6	Bibliothèques locales intermédiaires

Analyse

Les trois groupes sont désignés comme « Grands réseaux de bibliothèques », « Bibliothèques locales intermédiaires » et « Petites bibliothèques à forte offre technologique ». Ces appellations résument les principales caractéristiques observées dans la section précédente et facilitent l'interprétation des résultats.

7.2 Création du tableau synthèse des profils

Objectif

Présenter les principales caractéristiques des trois profils à partir des valeurs médianes.

Code

La fonction `aggregate()` est utilisée pour calculer la médiane de chacune des six variables pour chacun des trois groupes.

```
medianes_groupes <- aggregate(
  donnees_clustering,
  by = list(Groupe = clustering_final$cluster),
  FUN = median)
```

Le nombre de bibliothèques appartenant à chaque groupe est ensuite calculé.

```
taille_groupes <- table(clustering_final$cluster)
```

Les résultats sont finalement réunis dans un tableau synthèse contenant le nom du profil, le nombre de bibliothèques et les valeurs médianes des six variables.

```
tableau_profils <- data.frame(  
  Groupe = 1:3,  
  Profil = noms_profils,  
  Nb_bibliotheques = as.numeric(taille_groupes),  
  Population_mediane = medianes_groupes$Population_desservie,  
  Succursales_medianes = medianes_groupes$Nb_succursales,  
  Heures_ouverture_medianes = medianes_groupes$Heures_ouverture,  
  Superficie_mediane = medianes_groupes$Superficie,  
  Ratio_abonnes_median = medianes_groupes$Ratio_abonnes_population,  
  Indice_technologique_median =  
    medianes_groupes$Indice_ressources_technologiques  
)
```

Résultats

Le groupe 1 comprend 58 bibliothèques, le groupe 2 en comprend 180 et le groupe 3 en comprend 19. Les médianes obtenues sont les suivantes :

```
tableau_profils
```

	Groupe	Profil	Nb_bibliotheques
1	1	Grands réseaux de bibliothèques	58
2	2	Bibliothèques locales intermédiaires	180
3	3	Petites bibliothèques à forte offre technologique	19
		Population_mediane Succursales_medianes Heures_ouverture_medianes	
1		90043 5	251
2		6001 1	38
3		313 1	26
		Superficie_mediane Ratio_abonnes_median Indice_technologique_median	
1		51955 0.2445906	-0.2184468
2		4900 0.2187500	-0.1822750
3		1000 0.9139785	0.7305510

Analyse

Les médianes confirment les différences observées entre les trois profils.

Les grands réseaux desservent une population médiane de 90 043 personnes et comptent 5 succursales, mais présentent un indice technologique médian de -0,218.

Les bibliothèques locales intermédiaires desservent une population médiane de 6 001 personnes et affichent un indice technologique de -0,182.

Enfin, les petites bibliothèques à forte offre technologique desservent seulement 313 personnes en médiane, mais se distinguent par un ratio abonnés/population de 0,914 et l'indice technologique le plus élevé, à 0,731.

7.3 Création des profils standardisés

Objectif

Préparer les centres standardisés des trois groupes afin de faciliter leur comparaison et leur réutilisation dans le tableau de bord.

Code

Les centres obtenus par le modèle K-means sont réorganisés dans un tableau où chaque ligne correspond à une variable d'un profil

```
profils_standardises <- data.frame(  
  Groupe = integer(),  
  Profil = character(),  
  Variable = character(),  
  Score_Z = numeric(),  
  stringsAsFactors = FALSE  
)  
  
for (groupe in 1:3) {  
  for (i in 1:length(variables_clustering)) {  
    ligne <- data.frame(  
      Groupe = groupe,  
      Profil = noms_profils[groupe],  
      Variable = libelles_variables[i],  
      Score_Z = clustering_final$centers[groupe, i],  
      stringsAsFactors = FALSE  
    )  
    profils_standardises <- rbind(profils_standardises, ligne)  
  }  
}
```

Les scores Z sont arrondis à deux décimales.

```
profils_standardises$Score_Z <- round(profils_standardises$Score_Z, 2)
```

Résultats

Le tableau contient les scores Z des six variables pour chacun des trois profils.

profils_standardises

	Groupe	Profil
1	1	Grands réseaux de bibliothèques
2	1	Grands réseaux de bibliothèques
3	1	Grands réseaux de bibliothèques
4	1	Grands réseaux de bibliothèques
5	1	Grands réseaux de bibliothèques
6	1	Grands réseaux de bibliothèques
7	2	Bibliothèques locales intermédiaires
8	2	Bibliothèques locales intermédiaires
9	2	Bibliothèques locales intermédiaires
10	2	Bibliothèques locales intermédiaires
11	2	Bibliothèques locales intermédiaires
12	2	Bibliothèques locales intermédiaires
13	3	Petites bibliothèques à forte offre technologique
14	3	Petites bibliothèques à forte offre technologique
15	3	Petites bibliothèques à forte offre technologique
16	3	Petites bibliothèques à forte offre technologique
17	3	Petites bibliothèques à forte offre technologique
18	3	Petites bibliothèques à forte offre technologique
	Variable	Score_Z
1	Population desservie	1.28
2	Nombre de succursales	1.45
3	Heures d'ouverture	1.46
4	Superficie	1.31
5	Ratio abonnés/population	-0.15
6	Indice technologique	-0.29
7	Population desservie	-0.24
8	Nombre de succursales	-0.42
9	Heures d'ouverture	-0.38
10	Superficie	-0.30
11	Ratio abonnés/population	-0.21
12	Indice technologique	-0.14
13	Population desservie	-1.62
14	Nombre de succursales	-0.49
15	Heures d'ouverture	-0.83
16	Superficie	-1.14
17	Ratio abonnés/population	2.45
18	Indice technologique	2.18

Analyse

Les scores standardisés montrent que les grands réseaux se distinguent par leur taille, tandis que les petites bibliothèques se démarquent par leur ratio d'abonnés et leur offre technologique. Les bibliothèques intermédiaires demeurent légèrement sous la moyenne pour l'ensemble des variables.

7.4 Création du dossier de résultats

Objectif

Créer le dossier destiné à enregistrer les résultats du clustering.

Code

Le chemin du dossier de destination est d'abord défini. Le dossier Clustering sera placé à l'intérieur du dossier Resultats.

```
dossier_resultats <- file.path("Resultats", "Clustering")
```

Une condition vérifie ensuite si ce dossier existe déjà. S'il n'existe pas, il est créé.

```
if (!dir.exists(dossier_resultats)) {  
  dir.create(dossier_resultats, recursive = TRUE)  
}
```

Résultats

Le dossier Resultats/Clustering est créé.

Analyse

Cette étape prépare un emplacement commun pour les fichiers produits par l'analyse de clustering. Elle permet de regrouper les résultats dans un dossier distinct et d'éviter d'avoir à créer manuellement le dossier avant l'exécution du script.

7.5 Sauvegarde des résultats

Objectif

Enregistrer les résultats du clustering par bibliothèque et le tableau synthèse des trois profils.

Code

Le tableau contenant le groupe, le profil et les valeurs des variables pour chaque bibliothèque est d'abord enregistré au format CSV.

```
write.csv(  
  resultats_clustering,  
  file.path(dossier_resultats, "Resultats_clustering_bibliotheques.csv"),  
  row.names = FALSE,  
  fileEncoding = "UTF-8"  
)
```

Le tableau synthèse des trois profils est ensuite enregistré dans un second fichier CSV.

```
write.csv(  
  tableau_profils,  
  file.path(dossier_resultats, "Profils_bibliotheques.csv"),  
  row.names = FALSE,  
  fileEncoding = "UTF-8"  
)
```

Enfin, les centres standardisés des trois profils sont enregistrés dans un troisième fichier afin de permettre leur réutilisation dans les visualisations.

```
write.csv(  
  profils_standardises,  
  file.path(dossier_resultats, "Profils_standardises.csv"),  
  row.names = FALSE,  
  fileEncoding = "UTF-8"  
)
```

Résultats

Les trois fichiers sont créés dans le dossier Resultats/Clustering.

Analyse

Ces fichiers permettent de conserver les résultats du clustering et de les réutiliser dans le tableau de bord. Le premier contient les résultats par bibliothèque, le deuxième résume les caractéristiques des trois profils et le troisième contient leurs centres standardisés.

CONCLUSION

L'analyse de regroupement a fait ressortir trois profils généraux parmi les 257 bibliothèques disposant de données complètes. La solution à trois groupes a été retenue puisqu'elle présente la largeur moyenne de silhouette la plus élevée parmi les solutions comparées (0,445) et permet de distinguer des profils présentant des caractéristiques différentes. L'ACP complète cette analyse en montrant que les deux premières composantes résument 79,8 % de la variance et permettent de représenter les principales différences entre les groupes.

Le premier profil regroupe 58 grands réseaux de bibliothèques et se caractérise principalement par une population desservie, un nombre de succursales, des heures d'ouverture et une superficie élevés. Le deuxième comprend 180 bibliothèques locales intermédiaires, qui présentent des valeurs légèrement inférieures à la moyenne pour l'ensemble des variables. Enfin, le troisième profil rassemble 19 petites bibliothèques à forte offre technologique, qui se distinguent par un ratio abonnés/population et un indice technologique nettement plus élevés malgré leur faible taille.

L'analyse fait ainsi ressortir trois profils généraux à partir des caractéristiques étudiées. La séparation entre les groupes demeure toutefois modérée et 38 bibliothèques ont dû être exclues en raison de données manquantes. Les profils obtenus doivent donc être interprétés comme une représentation exploratoire de la structure des données plutôt que comme des catégories parfaitement distinctes.

BIBLIOGRAPHIE

- Bicanic, S. (2023). *Ontario public library statistics 2021* [Data set]. Kaggle.
<https://www.kaggle.com/datasets/sophiebicanic/ontario-public-library-statistics>
- Government of Ontario. (n.d.). *Ontario public library statistics* [Data set]. Ontario Data Catalogue.
<https://data.ontario.ca/en/dataset/ontario-public-library-statistics>
- Government of Ontario. (n.d.). *Open Government Licence – Ontario*.
<https://www.ontario.ca/page/open-government-licence-ontario>

ANNEXE

Bibliothèques exclues en raison de valeurs manquantes

	Nom_bibliotheque	Superficie	Indice_ressources_technologiques
13	Atikameksheng Anishnawbek Band No. 6 FN	NA	-0.26398600
16	Aundeck-Omni-Kaning FN	NA	1.05989455
20	Beausoleil First Nation Public Library	NA	2.88446632
36	Britt Area	NA	0.17749500
48	Casselman	NA	-0.19593696
61	Cobalt Twp	NA	0.42587125
66	Cramahe Twp	NA	-0.16757210
67	Curve Lake FN	NA	-0.12758681
71	Dokis FN	NA	1.87120932
72	Dorion Twp	NA	-0.06032825
75	Dubreuilville Twp	NA	0.35478266
81	Elizabethtown - Kitley	NA	-0.25312129
83	Emo Twp	NA	-0.21561363
88	Fauquier-Strickland Twp	NA	0.10530511
94	Garden River FN	NA	0.53157128
97	Gogama LSB	NA	-0.22642078
102	Greater Sudbury	NA	-0.23141518
126	Iskatewizaagegan No. 39 FN	NA	0.06241908
128	Kapuskasing	6400	NA
130	Kearney & Area	NA	-0.15994240
147	Loring, Port Loring and District Local Services Board	NA	0.25177530
159	McGarry Twp	NA	-0.17608709
166	Milton	NA	-0.20789273
173	Naotkamegwanning FN	NA	-0.09811037
179	Nipissing FN	NA	0.31974746
187	Ojibways of Onigaming FN	NA	-0.11308978
189	Opasatika	NA	0.45210974
197	Parry Sound	NA	-0.25741321
217	Red Lake	NA	-0.14561634
229	Seguin Twp	NA	-0.11361008
230	Seine River FN	NA	0.68817633
232	Serpent River FN	NA	0.01999508
236	Sioux Narrows Nestor Falls Twp	NA	0.50938484
244	St. Catharines	NA	-0.24075169
254	Tehkummah Twp	NA	0.02249186
260	Thessalon	NA	-0.19471784
272	Val Rita-Harty Twp	NA	1.55656199
274	Wahta Mohawk FN	NA	1.84598128