

Table des matières

1. Présentation générale du projet	2
1.1 Sujet, motivation et définition du projet	2
1.2 Objectifs du projet	4
1.3 Planification du projet	5
1.4 Évaluation de la performance de la réalisation	7
2. Explication des écarts de la réalisation par rapport à la planification	9
2.1 Résultats atteints par rapport aux objectifs initiaux	9
2.2 Justification des choix méthodologiques et techniques	15
2.3 Problèmes rencontrés et ajustements apportés	17
2.4 Limites du projet	19
3. Conclusion et recommandations	21
3.1 Bilan du projet	21
3.2 Apprentissage réalisé	22
3.3 Recommandations et perspectives	23
Bibliographie	24
Annexe	25

1. PRÉSENTATION GÉNÉRALE DU PROJET

1.1 Sujet, motivation et définition du projet

1.1.1 Sujet du projet

Le projet porte sur les bibliothèques publiques de l'Ontario et s'appuie sur le jeu de données *Ontario Public Library Statistics 2021*, trouvé sur la plateforme Kaggle. Ce jeu de données provient à l'origine du gouvernement de l'Ontario et regroupe des données sur 295 bibliothèques, notamment sur la population desservie, les ressources technologiques et certaines caractéristiques organisationnelles.

1.1.2 Motivation

Les bibliothèques publiques jouent un rôle important dans l'accès à la culture et aux technologies numériques. Leurs services sont nombreux et peuvent varier beaucoup d'une communauté à l'autre.

Ce sujet permet de travailler avec des données réelles et d'appliquer concrètement différentes méthodes de science des données. Il rejoint aussi directement le domaine des sciences de l'information et permet de mieux comprendre les différences entre les bibliothèques, notamment en ce qui concerne leur offre technologique.

1.1.3 Définition du projet

Le projet consiste à analyser les données des bibliothèques publiques de l'Ontario afin de mieux comprendre leurs caractéristiques, leur offre technologique et les différents profils d'établissements. La démarche couvre l'ensemble du processus d'analyse, depuis la préparation des données jusqu'à la communication des résultats.

Les données ont d'abord été nettoyées et enrichies afin de créer deux indicateurs, le ratio abonnés/population et l'indice de ressources technologiques. Les caractéristiques des bibliothèques et leurs relations avec l'offre technologique ont été étudiées à l'aide d'analyses descriptives et statistiques. Une régression linéaire multiple et une analyse en composantes principales (ACP) ont permis d'approfondir cette analyse, puis un clustering K-means a servi à identifier différents profils de bibliothèques.

Les principaux résultats ont été regroupés dans un tableau de bord interactif Power BI permettant de les visualiser et de les explorer. L'ensemble du projet, incluant les données, les scripts, les résultats et les rapports détaillés, est rendu public dans un dépôt GitHub.

1.2 Objectifs du projet

Le projet poursuit trois objectifs.

1.2.1 Brosser un portrait des bibliothèques publiques de l'Ontario

Le premier objectif est de brosser un portrait des bibliothèques à l'aide de statistiques descriptives et de graphiques. Il vise à mieux comprendre leurs principales caractéristiques et la diversité des établissements étudiés.

1.2.2 Analyser les facteurs associés à l'offre technologique

Le deuxième objectif est d'examiner les relations entre différentes caractéristiques des bibliothèques et leur offre technologique. Une attention particulière est accordée à la relation entre cette offre et le ratio abonnés/population.

1.2.3 Identifier des profils de bibliothèques publiques

Le troisième objectif est d'identifier différents profils de bibliothèques à partir des variables retenues. Des méthodes d'analyse multivariée et de regroupement permettent d'examiner les principales dimensions des données, puis de vérifier si certaines bibliothèques présentent des caractéristiques assez semblables pour former des groupes.

1.3 Planification du projet

1.3.1 Planification initiale

Le projet a été divisé en dix phases, de la recherche du sujet jusqu'à la remise finale.

Le tableau 1 résume cette planification.

Tableau 1 : Planification du projet

Phase	Période	Contenu principal
1. Recherche du sujet et documentation	4 au 8 juin 2026	Choix du sujet et des données, documentation et revue de la littérature.
2. Planification du projet	11 au 15 juin 2026	Définition des objectifs, questions, hypothèses et méthodologie.
3. Exploration des données	19 au 21 juin 2026	Exploration des données, repérage des anomalies et sélection des variables.
4. Préparation des données	22 au 26 juin 2026	Correction des anomalies et préparation des variables pour les analyses.
5. Création des indicateurs	27 au 30 juin 2026	Création et validation des deux indicateurs.
6. Analyse statistique	27 juillet au 21 août 2026	Analyses descriptives, corrélations, régression multiple et ACP.
7. Clustering et interprétation	9 au 16 août 2026	Clustering K-means et interprétation des profils.
8. Création du tableau de bord	22 au 26 août 2026	Création du tableau de bord et intégration des principaux résultats.
9. Documentation GitHub	27 août 2026	Organisation du dépôt GitHub et documentation des livrables.
10. Rapport final et communication	28 au 31 août 2026	Rédaction du rapport final et préparation de la présentation.

Le diagramme de Gantt présenté en annexe permet de visualiser cette planification dans le temps.

1.3.2 Risques anticipés

Quelques risques ont été considérés dès le début du projet. La qualité et la structure du jeu de données pouvaient demander plus de préparation que prévu. Les analyses statistiques pouvaient aussi faire ressortir des relations faibles ou difficiles à interpréter.

Le clustering comportait une autre incertitude puisque le nombre de groupes et leur qualité ne pouvaient pas être connus à l'avance. La quantité de résultats à présenter pouvait aussi compliquer la conception du tableau de bord.

Ces risques pouvaient demander d'ajuster certaines méthodes en cours de projet et, au besoin, de revoir l'échéancier.

1.4 Évaluation de la performance de la réalisation

La réalisation du projet peut être évaluée selon cinq dimensions : la concordance, la faisabilité, la complétude, la transférabilité et la qualité.

Concordance

Les méthodes et les outils utilisés sont directement liés aux objectifs du projet. La préparation et l'enrichissement des données permettent de construire les variables nécessaires aux analyses, tandis que les analyses statistiques, l'ACP et le clustering répondent aux questions de recherche. Le tableau de bord Power BI complète la démarche en permettant d'explorer et de communiquer les principaux résultats.

Les différentes étapes forment ainsi une démarche cohérente, de la préparation des données jusqu'à leur analyse et à la communication des résultats.

Faisabilité

Le projet a été réalisé dans la période prévue, avec les données et les outils disponibles, pour un total de 124 heures. Malgré certains ajustements en cours de réalisation, toutes les phases prévues ont pu être complétées.

R a été utilisé pour les analyses et Power BI pour la visualisation.

Complétude

Le projet couvre toute la démarche prévue, de la préparation des données jusqu'à la communication des résultats. Les données ont été nettoyées et enrichies, puis étudiées à l'aide d'analyses descriptives, statistiques et multivariées ainsi que d'un clustering.

Les résultats ont ensuite été intégrés à un tableau de bord interactif et la démarche a été documentée dans GitHub. Les trois objectifs du projet ont été abordés et tous les livrables prévus ont été réalisés.

Transférabilité

La démarche peut être reprise dans d'autres projets utilisant des données semblables. Les étapes de préparation, de validation, d'analyse, de regroupement et de visualisation peuvent facilement être adaptées à d'autres contextes.

Le projet montre aussi comment la science des données peut être appliquée aux sciences de l'information et à l'administration publique pour mieux comprendre des données et communiquer les résultats obtenus.

Qualité

La qualité du projet repose sur une démarche structurée, des choix méthodologiques justifiés et une interprétation prudente des résultats. Les données et les analyses ont été vérifiées à différentes étapes plutôt que d'accepter automatiquement les résultats obtenus.

Les scripts et les analyses ont aussi été documentés afin de pouvoir suivre et reproduire la démarche. Les limites sont clairement reconnues pour éviter de donner aux résultats une portée plus grande que ce qu'ils permettent réellement de conclure.

2. EXPLICATION DES ÉCARTS DE LA RÉALISATION PAR RAPPORT À LA PLANIFICATION

2.1 Résultats atteints par rapport aux objectifs initiaux

Les résultats sont présentés à partir des trois objectifs définis au début du projet. Ils permettent aussi de revenir sur les trois questions de recherche et les hypothèses formulées dans le plan initial. Pour plus de détails, les quatre rapports techniques sont joints au travail et peuvent être consultés avec le dépôt GitHub du projet.

2.1.1 Portrait des bibliothèques

Les 295 bibliothèques étudiées présentent des réalités très différentes. La population desservie varie de 48 à près de 3 millions de personnes, avec une médiane de 6 588. Le nombre de succursales varie de 1 à 100 et les heures d'ouverture de 5 à près de 5 700.




Figure 1. Distribution des principales caractéristiques des bibliothèques

Comme le montre la figure 1, les distributions sont asymétriques. La majorité des bibliothèques sont relativement petites, tandis que quelques grands réseaux se démarquent fortement. Le ratio abonnés/population présente une médiane de 0,24. Pour l'indice de ressources technologiques, construit à partir de variables standardisées et centré autour de 0, la médiane s'établit à -0,19.

Le réseau étudié est donc hétérogène.

L'analyse en composantes principales (ACP) permet de compléter ce portrait en examinant simultanément les cinq caractéristiques étudiées. Les deux premières composantes résument 88,21 % de leur variance. La première, qui explique 67,6 % de la variance, représente la taille du réseau en regroupant la population, la superficie, les heures d'ouverture et le nombre de succursales. La deuxième, qui en explique 20,6 %, fait ressortir le ratio d'abonnés. La figure 2 montre le positionnement des bibliothèques selon ces deux grandes dimensions.




Figure 2. Bibliothèques selon les deux premières composantes principales

Cette analyse permet de répondre au premier objectif du projet en caractérisant les bibliothèques et en faisant ressortir les principales dimensions qui les différencient. Le portrait descriptif montre que leur offre technologique varie selon les établissements.

2.1.2 Question de recherche 1 - Offre technologique et caractéristiques des bibliothèques

Quelles caractéristiques des bibliothèques publiques de l'Ontario sont associées à une offre technologique plus développée ?

Après transformation logarithmique, les relations présentées à la figure 3 montrent que la population desservie présente la relation la plus importante avec l'indice technologique ($r = -0,496$). La superficie ($r = -0,312$), les heures d'ouverture ($r = -0,236$) et le nombre de succursales ($r = -0,184$) présentent aussi des relations négatives, mais plus faibles.




Figure 3. Relations entre l'indice technologique et les caractéristiques des bibliothèques

La régression linéaire multiple apporte un résultat plus nuancé. Dans le modèle final, la superficie présente un coefficient négatif de $-0,275$, tandis que le ratio abonnés/population présente un coefficient positif de $0,403$. Comme le montre la figure 4, le modèle n'explique toutefois qu'environ 14 % des différences observées. Son pouvoir explicatif est donc faible.

```
summary(modele_regression)

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    1.27399    0.20819   6.119 3.54e-09 ***
Superficie_log -0.27462    0.05008  -5.483 1.01e-07 ***
Ratio_abonnes_log 0.40264    0.10225   3.938 0.000106 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5435 on 254 degrees of freedom
Multiple R-squared:  0.1493,    Adjusted R-squared:  0.1426
F-statistic: 22.28 on 2 and 254 DF,  p-value: 1.212e-09
```

Figure 4. Résumé du modèle final de régression linéaire multiple

Hypothèse 1 - Population desservie et offre technologique

Il existe une relation positive entre la taille de la population desservie et l'indicateur d'offre technologique des bibliothèques.

Cette hypothèse n'est pas confirmée. La relation observée est négative, mais elle doit être interprétée avec prudence puisque la population intervient dans la construction de l'indice technologique.

2.1.3 Question de recherche 2 - Offre technologique et utilisation

Existe-t-il une relation entre l'offre technologique des bibliothèques publiques de l'Ontario et leur ratio abonnés/population ?

Les résultats montrent une relation positive, mais faible. Dans les données non transformées, le ratio abonnés/population présente une corrélation de 0,222 avec l'indice technologique. Après transformation logarithmique, cette relation demeure positive, mais devient plus faible ($r = 0,126$). La régression multiple va dans le même sens, avec un coefficient positif de 0,403 ($p < 0,001$).

Hypothèse 2 – Offre technologique et utilisation

Il existe une relation positive entre l'indicateur d'offre technologique et le ratio abonnés/population.

Les résultats soutiennent cette hypothèse, mais la relation demeure faible. La corrélation montre une association positive entre le ratio abonnés/population et l'indice technologique, et cette relation demeure positive et statistiquement significative dans le modèle de régression multiple. Le faible pouvoir explicatif du modèle indique toutefois qu'une grande partie des différences observées entre les bibliothèques n'est pas expliquée par les variables retenues.

2.1.4 Question de recherche 3 - Profils de bibliothèques

Peut-on identifier différents profils de bibliothèques publiques de l'Ontario à partir des variables retenues ?

Le clustering K-means a permis d'identifier trois profils. Le premier regroupe 58 grands réseaux, le deuxième 19 petites bibliothèques à forte offre technologique et le troisième 180 bibliothèques locales intermédiaires.




Figure 5. Profil standardisé des trois groupes

La figure 5 montre que les grands réseaux se distinguent surtout par les variables liées à la taille. Les petites bibliothèques à forte offre technologique se démarquent par leur ratio abonnés/population et leur indice technologique. Les bibliothèques intermédiaires restent plus près de la moyenne.

Les profils observés ne se distinguent donc pas uniquement par la taille du réseau, mais aussi par le ratio d'abonnés et l'offre technologique. La silhouette moyenne de 0,445 indique toutefois que la séparation entre les groupes est modérée.

Hypothèse 3 – Profils de bibliothèques

Il est possible d'identifier des groupes de bibliothèques présentant des caractéristiques similaires à partir des variables retenues pour les analyses.

Cette hypothèse est appuyée par les résultats. Trois profils ont pu être dégagés et interprétés, même s'ils représentent davantage des tendances générales que des catégories parfaitement distinctes.

2.2 Justification des choix méthodologiques et techniques

Les méthodes, les techniques et les outils ont été choisis selon les objectifs du projet et les caractéristiques des données.

2.2.1 Approche et méthodes

Les statistiques descriptives ont été utilisées pour brosser un portrait général des bibliothèques, tandis que les corrélations ont permis d'étudier les relations entre les variables.

La régression multiple a été utilisée pour examiner plusieurs caractéristiques simultanément et mieux comprendre leur relation avec l'indice technologique. L'ACP a permis d'obtenir une vue d'ensemble des données et de faire ressortir leurs principales dimensions. Le clustering K-means a été retenu pour rechercher des profils de bibliothèques sans définir les groupes à l'avance.

Ces méthodes permettent de répondre aux trois objectifs du projet.

2.2.2 Techniques appliquées

Les techniques ont été adaptées aux caractéristiques des données. Les variables fortement asymétriques ont été transformées en logarithme afin de réduire l'effet des valeurs très élevées. Les variables utilisées pour le K-means ont été standardisées afin qu'elles soient comparables et qu'aucune ne domine le regroupement en raison de son échelle.

Les corrélations de Pearson ont été utilisées pour étudier les relations linéaires entre les variables numériques. Les conditions de la régression ont été vérifiées à l'aide de diagnostics. Pour le clustering, la méthode du coude et l'indice de silhouette ont permis de comparer plusieurs nombres de groupes.

Les détails de ces choix et de leur application sont présentés dans les rapports techniques disponibles dans le dépôt GitHub.

2.2.3 Outils utilisés

Les outils ont été choisis selon leur rôle. R et RStudio ont servi à préparer les données et à réaliser les analyses statistiques et le clustering. Power BI a été utilisé pour regrouper les résultats dans un tableau de bord interactif et permettre leur exploration. GitHub rassemble les scripts, les données, les résultats et les rapports afin de faciliter le suivi et la reproduction de la démarche.

2.3 Problèmes rencontrés et ajustements apportés

Certaines difficultés ont demandé des ajustements pendant le projet. Elles ont surtout touché la préparation des données, les analyses statistiques, le clustering et le tableau de bord, avec certaines conséquences sur l'échéancier.

Importation des données

Le premier problème est apparu dès l'importation. Le fichier brut comportait des problèmes de structure, dont huit observations décalées par des virgules dans les noms de bibliothèques. Ces lignes ont été reconstruites avant de poursuivre la préparation.

Certaines valeurs atypiques ou incohérentes ne pouvaient pas non plus être corrigées avec certitude. Elles ont été vérifiées selon leur contexte. Lorsque la bonne valeur ne pouvait pas être déterminée, elles ont été remplacées par une valeur manquante. Certaines analyses ont ainsi porté sur 257 des 295 bibliothèques plutôt que d'utiliser des valeurs estimées peu fiables.

Analyse statistique

L'analyse statistique a connu l'ajustement le plus important. Spearman a été retiré, puisque la corrélation de rang était peu adaptée aux variables numériques étudiées. L'analyse initiale, principalement fondée sur les corrélations de Pearson, a ensuite été approfondie par une régression multiple et une ACP. Ces méthodes ont permis d'étudier plusieurs variables simultanément et de mieux comprendre les relations observées.

La régression a elle-même demandé des ajustements. Le premier modèle présentait une forte multicolinéarité et certains diagnostics montraient des limites. Plusieurs modèles ont donc été comparés avant de retenir une solution plus simple et plus facile à interpréter.

Clustering

Le choix du nombre de groupes a également demandé un ajustement. La méthode du coude ne permettait pas de dégager une solution claire. Les solutions de deux à cinq groupes ont donc été comparées à l'aide de l'indice de silhouette.

La solution à trois groupes a finalement été retenue. Sa silhouette moyenne de 0,445 montre toutefois que la séparation entre les groupes reste modérée. Les profils obtenus doivent être interprétés comme des tendances générales plutôt que comme des catégories parfaitement distinctes.

Tableau de bord

Le tableau de bord a évolué progressivement pendant sa conception. Les onglets et la présentation ont été ajustés à mesure que les résultats des différentes analyses étaient intégrés.

Ces ajustements visaient surtout à éviter de surcharger les visuels et à rendre l'exploration plus simple. Le tableau de bord final regroupe les principaux résultats tout en permettant au lecteur de les explorer de manière interactive.

Échéancier

L'échéancier a été ajusté en fin de projet, principalement pour approfondir l'analyse statistique avec la régression multiple et l'ACP.

Ce travail supplémentaire a repoussé les dernières phases du projet, notamment la création du tableau de bord, la documentation GitHub et la finalisation du rapport.

Malgré ces ajustements, toutes les phases prévues ont été réalisées dans la période accordée au projet.

2.4 Limites du projet

Les résultats doivent être interprétés en tenant compte de six principales limites.

Données limitées à l'année 2021

Les données portent uniquement sur 2021. Elles donnent donc un portrait des bibliothèques à un moment précis, sans permettre d'étudier leur évolution dans le temps.

Variables disponibles

Les analyses sont limitées aux variables présentes dans le jeu de données. D'autres facteurs, comme les budgets, les caractéristiques socioéconomiques, les choix de gestion ou les besoins des communautés, pourraient contribuer aux différences observées.

Construction de l'indice technologique

La population intervient directement dans la construction de l'indice technologique puisque les cinq ressources sont d'abord calculées par 1 000 habitants. La relation entre la population et cet indice doit donc être interprétée avec prudence.

Portée de l'indice technologique

L'indice a été construit pour ce projet à partir de cinq types de ressources technologiques. Il permet de comparer les bibliothèques selon ces ressources, mais ne couvre pas toutes les dimensions de leur offre technologique.

Limites de la régression

Le modèle retenu explique seulement environ 14 % des différences observées dans l'indice technologique. Ses diagnostics montrent aussi des écarts aux conditions du modèle et quelques observations se distinguent fortement. Une grande partie des différences entre les bibliothèques reste donc inexpliquée.

Portée des relations observées

Les corrélations et la régression permettent de relever des associations entre les caractéristiques des bibliothèques, mais ne permettent pas d'établir des relations de cause à effet.

Ces limites n'empêchent pas de dégager des tendances utiles, mais elles invitent à considérer les résultats comme un portrait exploratoire des bibliothèques publiques de l'Ontario en 2021.

3. CONCLUSION ET RECOMMANDATIONS

3.1 Bilan du projet

Les bibliothèques publiques de l'Ontario présentent des réalités très différentes. Les grands réseaux desservent plus de personnes, possèdent plus de succursales et offrent davantage d'heures d'ouverture, mais ils n'ont pas nécessairement plus de ressources technologiques par rapport à leur population. Certaines petites bibliothèques se démarquent même par une offre technologique importante.

Les analyses montrent que cette offre ne dépend pas d'une seule caractéristique. La population desservie et la proportion d'abonnés actifs sont notamment liées à cette offre. Les trois profils obtenus permettent de mieux représenter ces différences.

Ces résultats peuvent aider les responsables à comparer leur bibliothèque à d'autres qui ont des caractéristiques semblables. Le tableau de bord permet d'ailleurs d'explorer facilement ces comparaisons.

Dans un contexte où les bibliothèques jouent un rôle important dans l'accès aux technologies, les petites bibliothèques qui offrent beaucoup de ressources technologiques par rapport à leur population sont particulièrement intéressantes. Étudier leurs pratiques pourrait permettre de mieux comprendre leurs résultats et d'inspirer d'autres bibliothèques ayant une réalité semblable.

3.2 Apprentissage réalisé

3.2.1 Ce que je ferais différemment

Si je devais reprendre ce projet, je réfléchirais davantage aux variables et aux méthodes d'analyse dès le départ. Cela m'aurait permis de repérer plus tôt certaines limites de l'indice technologique.

Je prévoirais aussi la régression et l'ACP dès le début. Elles ont permis d'aller plus loin que les corrélations et auraient rendu l'analyse statistique mieux structurée.

Enfin, je réserverais plus de temps pour la fin du projet. L'ajout de nouvelles analyses a demandé de modifier les résultats et les rapports pour que tous les livrables restent cohérents.

3.2.2 Apprentissage le plus significatif

Mon principal apprentissage concerne l'interprétation des résultats. Une relation qui semble simple peut devenir plus complexe lorsqu'on l'analyse avec plusieurs méthodes. La relation entre la population et l'indice technologique en est un bon exemple, puisque la population entre aussi dans le calcul de cet indice.

J'ai aussi appris qu'il ne faut pas retenir automatiquement le premier résultat obtenu. Pour la régression et le clustering, plusieurs solutions ont dû être comparées avant de choisir celles qui étaient les plus pertinentes.

J'ai donc appris à accorder autant d'importance à la construction des variables et à l'interprétation des résultats qu'aux analyses elles-mêmes.

3.3 Recommandations et perspectives

Une première piste serait d'analyser plusieurs années afin de vérifier si les petites bibliothèques qui offrent beaucoup de ressources technologiques se démarquent toujours et si les trois profils restent semblables dans le temps.

D'autres données pourraient aussi aider à expliquer les différences entre les bibliothèques, comme leur financement, la densité de population, le revenu médian ou le niveau de scolarité des communautés desservies.

L'indice technologique pourrait aussi être amélioré en comparant les ressources par habitant, par abonné actif ou en quantité brute. Des données sur leur utilisation, les services numériques, les activités de littératie numérique et les dépenses technologiques permettraient aussi de compléter cet indice.

Enfin, il serait intéressant d'étudier les pratiques des petites bibliothèques qui se démarquent par leur offre technologique. Cela permettrait de mieux comprendre leurs résultats et de voir si certaines pratiques peuvent inspirer des bibliothèques semblables.

BIBLIOGRAPHIE

- Bicanic, S. (2023). *Ontario public library statistics 2021* [Data set]. Kaggle.
<https://www.kaggle.com/datasets/sophiebicanic/ontario-public-library-statistics>
- Government of Ontario. (n.d.). *Ontario public library statistics* [Data set]. Ontario Data Catalogue.
<https://data.ontario.ca/en/dataset/ontario-public-library-statistics>
- Government of Ontario. (n.d.). *Open Government Licence – Ontario*.
<https://www.ontario.ca/page/open-government-licence-ontario>

ANNEXE

Journal des activités

Date	Heures	Phase	Synthèse des activités
4 juin	2 h 30	1	Choix du sujet et du jeu de données. Première exploration du contenu et définition des grandes orientations du projet.
5 juin	3 h	1	Recherche documentaire sur les bibliothèques publiques de l'Ontario et courte revue de la littérature.
8 juin	2 h	1	Poursuite de la documentation et sélection des sources utiles pour définir le contexte du projet.
11 juin	3 h	2	Révision des objectifs, des questions de recherche et des hypothèses. Réflexion sur les indicateurs et la méthodologie.
12 juin	2 h 30	2	Révision du plan de projet et harmonisation des objectifs, des hypothèses et de la méthodologie.
13 juin	2 h	2	Révision de la problématique et des sources. Recentrage du projet sur l'offre technologique.
14 juin	2 h 30	2	Finalisation de la méthodologie, du calendrier et du diagramme de Gantt.
19 juin	3 h	3	Début de l'exploration dans R. Vérification de la structure du fichier et repérage des problèmes d'importation.
20 juin	2 h 30	3	Vérification des variables, des valeurs manquantes et de la structure générale des données.
21 juin	2 h 30	3	Analyse des anomalies d'importation, vérification des valeurs aberrantes et sélection des variables utiles au projet.
22 juin	4 h	4	Correction de la structure du fichier et des problèmes d'importation. Conversion des variables au bon format.
23 juin	3 h 30	4	Vérification de la cohérence des données et traitement des valeurs incohérentes ou aberrantes.
24 juin	4 h	4	Poursuite du nettoyage et traitement des valeurs qui ne pouvaient pas être corrigées de façon fiable.
25 juin	3 h	4	Révision du script de préparation, validation des corrections et amélioration des justifications méthodologiques.
26 juin	2 h	4	Finalisation de la préparation des données et vérification du jeu de données avant la création des indicateurs.

27 juin	2 h 30	5	Création de la population desservie, du ratio abonnés/population et des ressources technologiques par 1 000 habitants.
29 juin	2 h 30	5	Standardisation des variables technologiques et création de l'indice global de ressources technologiques.
30 juin	2 h	5	Validation des indicateurs à l'aide de statistiques descriptives et de graphiques.
27 juillet	4 h	6	Développement du script d'analyse : statistiques descriptives, graphiques et premières corrélations de Pearson.
28 juillet	3 h	6	Poursuite des analyses et rédaction des sections sur les statistiques descriptives et les visualisations.
29 juillet	3 h 30	6	Ajout de la transformation logarithmique et comparaison des résultats avec les données originales.
30 juillet	3 h	6	Ajout des corrélations de Spearman et comparaison avec les corrélations de Pearson réalisées sur les données originales et transformées.
1er août	3 h 30	6	Finalisation du rapport d'analyse et du rapport de mi-parcours. Mise à jour du calendrier et du journal de bord.
9 août	1 h 30	7	Recherche sur le regroupement K-means, préparation des variables et premiers essais dans R.
11 août	2 h	7	Standardisation des variables, essais avec différentes valeurs de k, méthode du coude et coefficient de silhouette.
13 août	1 h 30	7	Analyse des premiers résultats, transformation logarithmique et reprise du clustering.
15 août	4 h	7	Finalisation du clustering K-means, analyse des trois groupes et production des tableaux et graphiques.
16 août	3 h	7	Finalisation du script, rédaction et révision du rapport de clustering.

18 août	2 h	6	Retrait de Spearman et préparation des analyses supplémentaires. Recherche et préparation de la régression linéaire multiple.
19 août	3 h	6	Développement de la régression linéaire multiple. Vérification des relations entre les variables explicatives, comparaison et simplification des modèles.
20 août	4 h	6	Détermination du modèle retenu, vérification des diagnostics et interprétation des résultats. Préparation de l'ACP.
21 août	4 h	6	Réalisation et finalisation de l'ACP et de ses visualisations. Révision du script et du rapport d'analyse statistique.
22 août	5 h	8	Planification du tableau de bord. Définition des pages et des indicateurs. Développement des pages Portrait et Relations.
23 août	5 h	8	Développement des pages Profils et Explorer. Intégration des résultats du clustering et ajout des principales interactions.
24 août	2 h	8	Amélioration des filtres, des interactions et de la navigation.
25 août	2 h	8	Ajustement des visualisations et vérification du fonctionnement des différentes pages.
26 août	4 h	8	Ajustement de la disposition mobile, tests finaux et corrections. Publication du tableau de bord, vérification de la version Web et finalisation du rapport de conception.
27 août	3 h	9	Organisation et finalisation du dépôt GitHub. Sélection et téléversement des fichiers, révision du README et vérification finale de la structure et des liens.
28 août	2 h	10	Planification et restructuration du rapport final à partir des différents livrables produits au cours du projet.
29 août	4 h	10	Intégration et synthèse des sections portant sur la préparation des données, les analyses statistiques et le clustering.
30 août	3 h	10	Intégration du tableau de bord. Rédaction des sections de synthèse et de conclusion. Harmonisation des tableaux, figures et différentes sections du rapport.
31 août	2 h	11	Mise à jour du journal de bord, vérification des références, figures, tableaux et du dépôt GitHub. Corrections finales et préparation de la remise.

Diagramme de Gantt

Tâches principales	Juin				Juillet								Août									
	8 juin	15 juin	22 juin	29 juin	6 juillet	13 juillet	20 juillet	27 juillet	3 août	10 août	17 août	24 août	31 août									
1. Recherche du sujet et documentation																						
2. Planification et gestion de projet																						
3. Compréhension et exploration des données																						
4. Nettoyage et préparation des données																						
5. Création d'indicateurs																						
6. Analyses statistiques																						
7. Clustering et interprétation																						
8. Création du tableau de bord																						
9. Documentation GitHub																						
10. Rapport final																						